

Fine-tuning do MLLM LLaMA para a Classificação de Lesões de Pele e Geração de Laudos

Eric Fernandes Evaristo¹, Aldo von Wangenheim¹, Rodrigo de Paula e Silva Ribeiro¹

¹Departamento de Informática e Estatística
Centro Tecnológico – Universidade Federal de Santa Catarina (UFSC)

Resumo. A detecção precoce de lesões de pele é crucial para o tratamento de doenças graves, como o câncer de pele, mas o diagnóstico destas lesões requer um dermatologista. No Brasil, os Agentes Comunitários de Saúde (ACS) têm contato direto com a população, porém não possuem a qualificação necessária para realizar a triagem de lesões de pele. Diante disso, uma ferramenta que pudesse classificar essas lesões e fornecer pré-diagnósticos seria de grande auxílio. Neste contexto, os Multimodal Large Language Models (MLLMs) se mostram promissores, pois possuem a capacidade de interpretar imagens e gerar dados textuais.

Este trabalho avaliou o uso do Large Language Model Meta AI (LLaMA) 3.2 11B, para classificar lesões de pele e gerar laudos. Os experimentos foram divididos em duas etapas, com o fine-tuning sendo realizado em conjuntos de dados diferentes em cada uma delas. Na primeira etapa, usando o conjunto de dados de dermatoscopia Human Against Machine with 10000 training images (HAM10000) apenas para classificação, o modelo alcançou uma acurácia de 86,2% com Low-Rank Adaptation (LoRA). Enquanto na segunda etapa, que visava a classificação e a geração de laudos com um conjunto de dados proveniente do Sistema Integrado Catarinense de Telemedicina e Telessaúde (STT/SC), o desempenho caiu significativamente, com o modelo atingindo uma acurácia de 45,2% com Quantized Low-Rank Adaptation (QLoRA) e 44,5% com LoRA. O baixo desempenho dos modelos finais na classificação pode ser explicado por inconsistências no conjunto de dados.

Palavras-chave: Lesões de pele. Câncer de pele. MLLM. LLaMA. PEFT. Fine tuning. QLoRA. LoRA.

1. Introdução

Lesões de pele são áreas anormais ou danificadas da pele, causadas por diversos fatores, como condições ambientais, infecções ou doenças graves, incluindo o câncer de pele. A identificação precisa da causa é fundamental para o tratamento adequado, porém, devido à semelhança entre os sintomas, o diagnóstico correto das doenças de pele pode ser uma tarefa complexa. Além disso, o prognóstico pode se agravar significativamente se o tratamento não for iniciado cedo o suficiente (HABIF, 2015).

A importância do cuidado com lesões de pele é evidenciada pelo impacto do câncer de pele. No Brasil, 30% dos tumores malignos registrados são atribuídos a essa doença (MINISTÉRIO DA SAÚDE, 2020). Os tipos mais comuns, o carcinoma basocelular e o carcinoma epidermoide, apresentam baixa letalidade, mas podem deixar sequelas significativas devido ao tratamento. Já o melanoma, embora menos frequente, é altamente letal e corresponde a cerca de 75% das mortes causadas pelo câncer de pele (MAUAD et

al., 2011). A detecção precoce é essencial para a eficácia do tratamento, pois a taxa de sobrevida dos pacientes tende a cair com o avanço da doença (LIMA VAZQUEZ et al., 2015).

A dificuldade da identificação precoce de lesões de pele tem um componente socioeconômico. Em um estudo feito por Youl et al. (2011), observa-se que indivíduos com um grau menor de escolaridade têm um prognóstico pior, pois apresentam tumores em estágios mais avançados. Esta correlação pode indicar que a desigualdade resulta no atraso do diagnóstico e consequentemente na redução da taxa de sucesso do tratamento. Santos (2020) também constata que a saúde dos brasileiros está associada à renda e classe econômica.

No Brasil, uma parte da atenção primária é feita por ACS, que possuem um treinamento básico para atender a população e fornecer orientações básicas de saúde. Esses são os profissionais que normalmente estão em contato com as regiões mais carentes. A identificação da causa de uma lesão de pele está além das responsabilidades de um ACS (FILGUEIRAS; SILVA, 2011). Isso pode ser problemático, pois a triagem de um caso de lesão de pele requer a análise de um dermatologista, que nem sempre está disponível em regiões carentes.

Considerando este cenário, seria útil um serviço com boa usabilidade que analisasse imagens de pacientes e recomendasse uma forma de triagem, de modo a mitigar a carência por dermatologistas. As capacidades de classificar e descrever imagens com precisão tornam os MLLMs bons candidatos para fundamentar tal serviço (PANAGOULIAS; VIRVOU; TSIHRINTZIS, 2024).

Neste trabalho, o LLaMA-3.2-11B foi escolhido como modelo base para o desenvolvimento por ser de código aberto e por sua relevância no estado da arte para tarefas visuais e textuais (DUBEY et al., 2024). O modelo foi submetido ao *fine-tuning* com diferentes técnicas de treinamento ao longo de duas etapas, nas quais se utilizaram os conjuntos de dados HAM10000 e STT/SC para adaptá-lo às tarefas de classificação de lesões de pele e geração de laudos.

Com o objetivo de utilizar eficientemente os recursos computacionais disponíveis, o *fine-tuning* foi realizado com técnicas baseadas em *Parameter-Efficient Fine-Tuning* (PEFT). Este método permite a redução do número de parâmetros treinados, resultando em um menor consumo de recursos (PEFT, 2021). Especificamente, utilizaram-se os métodos QLoRA e LoRA para o treinamento do modelo.

1.1. Objetivos

O objetivo principal deste trabalho é treinar um *Large Language Model* (LLM) multimodal com métodos de *fine-tuning* para a classificação de lesões de pele e geração de laudos, avaliando o desempenho dos modelos resultantes e comparando as diferentes técnicas de treinamento.

Objetivos Específicos

- Realizar o *fine-tuning* do modelo LLaMA-3.2-11B com as técnicas de treinamento QLoRA e LoRA;

- Comparar os modelos resultantes do processo de *fine-tuning* com o LLaMA-3.2-11B;
- Comparar os modelos resultantes entre si a fim de avaliar o impacto das diferentes técnicas de treinamento.

2. Metodologia de Desenvolvimento

O experimentos foram realizados em duas etapas, sendo que as ferramentas utilizadas em cada etapa foram as mesmas. Os *scripts* foram implementados com Python 3.10 e *Jupyter Notebooks*. Os treinamentos foram realizados com a plataforma NVIDIA DGX H100, fazendo o uso de apenas uma placa NVIDIA H100 e 80 GB de memória.

Na primeira etapa o conjunto de dados de imagens de dermatoscopia HAM10000 foi utilizado, contendo 13354 imagens. Foram feitos treinamentos com 450, 900 e 5000 amostras com os métodos QLoRA e LoRA. O *fine-tuning* foi aplicado com um modelo conversacional em que um *prompt* de pergunta sobre a imagem de uma lesão é fornecido ao modelo, assim, o modelo responde informando a lesão de pele em questão.

A segunda etapa se consistiu do *fine-tuning* com o conjunto de dados proveniente do STT/SC. Os dados foram tratados e 4736 pares de imagem e texto foram selecionadas para o treinamento, enquanto 1167 pares foram selecionados para o teste. Foi realizado o treinamento com QLoRA e LoRA para classificação de lesões de pele, classificação de categorias de risco e geração de laudos.

3. Resultados e Discussão

Nesta seção serão apresentados os resultados e será realizada uma análise comparativa dos modelos resultantes do *fine-tuning* realizado nas duas etapas de desenvolvimento. Além disso serão feitas comparações com o modelo base e entre os métodos de treinamento.

3.1. Desempenho na Classificação de Lesões de Pele

A Subseção 3.1 apresenta uma comparação entre todos os testes realizados.

Tipo de imagem	Método de <i>fine-tuning</i>	Volume de treinamento	Acurácia (%)
Dermatoscopia	Nenhum (Quantizado)	-	11,8
	Nenhum	-	14,0
	QLoRA	450	65,5
		900	65,2
		5000	85,4
	LoRA	450	49,5
		900	42,0
		5000	86,2
Aproximação	Nenhum (Quantizado)	-	14,8
	Nenhum	-	17,0
	QLoRA	4736	45,2
	LoRA	4736	44,5

Tabela 1. Acurácia na classificação de lesões de pele nos testes realizados. Os valores em negrito indicam as maiores acurácias para o tipo de imagem especificado. Fonte: Autoria própria.

Os resultados obtidos na etapa final de desenvolvimento indicam que os modelos que passaram pelo *fine-tuning* para a classificação de lesões de pele com imagens de aproximação obtiveram um desempenho mediano, ficando abaixo do esperado. Em comparação com os modelos da primeira etapa, treinados para a classificação com imagens de dermatoscopia, a acurácia foi consideravelmente menor.

Os modelos da primeira etapa obtiveram um desempenho superior com um quantidade muito menor de dados, comparativamente, o modelo treinado com QLoRA e 5000 imagens de dermatoscopia superou o modelo treinado com QLoRA e 4736 imagens de aproximação em 42,2%. Embora existam diferenças nos hiperparâmetros de treinamento desses modelos, a divergência é significativa demais para estar relacionada apenas com os hiperparâmetros.

3.2. Desempenho na Classificação de Risco

A classificação de risco introduzida na etapa final do trabalho apresentou um cenário mais promissor no desempenho, porém a acurácia ainda foi mediana e pouco satisfatória. A Subseção 3.2 apresenta uma visão comparativa da acurácia na classificação das categorias de risco, evidenciando as melhorias no desempenho proporcionadas pelo *fine-tuning*.

Método de <i>fine-tuning</i>	Acurácia (%)
Nenhum (Quantizado)	23,4
Nenhum	27,4
QLoRA	54,6
LoRA	55,1

Tabela 2. Acurácia na classificação de risco para os testes da etapa final de desenvolvimento. O valor em negrito indica a maior acurácia. Fonte: Autoria própria.

3.3. Desempenho na Geração de Laudos

O desempenho na geração de texto foi considerado satisfatório, conforme pode ser visto na Subseção 3.3, tanto o modelo treinado com o QLoRA quanto o com LoRA atingiram um desempenho superior ao do modelo base, constatando que os modelos conseguiram generalizar o formato de geração do texto do laudo. Nas métricas *Bilingual Evaluation Understudy* (BLEU) e *Metric for Evaluation of Translation with Explicit Ordering* (METEOR) foi observado o maior ganho de desempenho em relação ao modelo base, enquanto na métrica *Recall-Oriented Understudy for Gisting Evaluation* (ROUGE) o ganho de desempenho foi menor.

Métrica	Método de <i>fine-tuning</i>			
	Nenhum (Quantizado)	Nenhum	QLoRA	LoRA
BLEU-1	0,181	0,192	0,551	0,545
BLEU-2	0,125	0,129	0,524	0,517
BLEU-3	0,099	0,102	0,511	0,504
BLEU-4	0,081	0,083	0,500	0,493
ROUGE-1 (<i>recall</i>)	0,422	0,417	0,678	0,677
ROUGE-L (<i>recall</i>)	0,330	0,313	0,629	0,627
METEOR	0,211	0,221	0,580	0,576

Tabela 3. Métricas de PLN do texto das respostas geradas sobre os testes na etapa final de desenvolvimento. Os maiores valores de cada métrica estão destacados em negrito. Fonte: Autoria própria.

A fim de realizar uma análise aprofundada da geração de texto, as respostas abaixo foram coletadas dos resultados dos testes. Primeiramente, o texto de referência é apresentado:

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).
Classificação de risco: AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO.
Conclusão sobre a lesão: compatível com câncer da pele.
Conclusão: Encaminhar o paciente para o ambulatório de Dermatologia - CÂNCER DA PELE/Cirurgia Dermatológica ou referência regional.

Se o paciente já realizou biópsia da lesão, o resultado deve ser levado no dia da cirurgia.

As duas respostas abaixo foram geradas pelo LLaMA-3.2-11B quantizado e não quantizado, respectivamente. Os modelos classificaram corretamente a lesão de pele, mas apenas a versão quantizada categorizou o risco de forma correta. Além disso, as conclusões não apresentaram as recomendações ideais.

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).
Classificação de risco: AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO.

Conclusão sobre a lesão: A lesão apresentada na imagem é caracterizada por uma lesão de pele com aspecto ulcerado e com bordas irregulares, o que sugere uma lesão maligna. A classificação de risco como amarela indica que a lesão requer acompanhamento e tratamento em um ambulatório de referência terciário.

Conclusão: A lesão apresentada na imagem é suspeita de câncer de pele não melanoma e requer acompanhamento e tratamento em um ambulatório de referência terciário.

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).

Classificação de risco: BRANCA - SEM NECESSIDADE DE INTERVENÇÃO OU ACOMPANHAMENTO.

Conclusão sobre a lesão: A lesão apresentada na imagem é caracterizada por uma lesão de pele com uma borda irregular e um centro escuro, o que sugere uma lesão maligna. A presença de uma lesão de pele com essas características é compatível com um Câncer de pele Não Melanoma (CEC ou CBC).

Conclusão: A lesão apresentada na imagem é compatível com um Câncer de pele Não Melanoma (CEC ou CBC) e deve ser avaliada por um especialista em dermatologia.

As respostas seguintes foram geradas com o LLaMA-3.2-11B treinado com QLoRA e LoRA, respectivamente. Ambos classificaram as lesões e as categorias de risco corretamente. As conclusões geradas seguem o texto de referência com precisão, mas apresentam a palavra “compatível” com a grafia incorreta, omitindo o acento agudo. O texto gerado também inclui um espaçamento inesperado.

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).

Classificação de risco: AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO.

Conclusão sobre a lesão: compatível com câncer da pele.

Conclusão: Encaminhar o paciente para o ambulatório de Dermatologia - Câncer da Pele/Cirurgia Dermatológica ou referência regional.

Se o paciente já realizou biópsia da lesão, o resultado deve ser levado no dia da cirurgia.

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).

Classificação de risco: AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO.

Conclusão sobre a lesão: compatível com câncer da pele.

Conclusão: Encaminhar o paciente para o ambulatório de Dermatologia -

CÂNCER DA PELE/Cirurgia Dermatológica ou referência regional.

Se o paciente já realizou biópsia da lesão, o resultado deve ser levado no dia da cirurgia.

3.4. Comparação entre as Técnicas de Treinamento

Por fim, comparando as métricas de treinamento apresentadas na Subseção 3.4, Figura 3.4 e Figura 3.4, observa-se que ambos os métodos de treinamento tomam uma quantidade similar de tempo para serem concluídos. O tempo de treinamento também tende a escalar na mesma taxa para ambos os métodos, mesmo com diferentes volumes de dados. Ademais, o método LoRA tende a utilizar uma quantidade maior de memória, com um uso médio de 84,19% a mais de memória em relação ao QLoRA na etapa inicial. Na etapa final, o LoRA utilizou 25,94% a mais de memória. A disparidade entre essas diferenças para as duas etapas pode ser explicada pelas alterações nos hiperparâmetros que afetam o uso da memória, como tamanho do lote por dispositivo e o passo de acumulação de gradiente. Além disso, é possível que as características do conjunto de dados tenham influenciado nesta diferença.




Figura 1. Tempo de treinamento dos modelos da etapa inicial com diferentes técnicas de treinamento. Fonte: Autoria própria.




Figura 2. Memória utilizada no treinamento dos modelos da etapa inicial com diferentes técnicas de treinamento. Fonte: Autoria própria.

Método de treinamento	Tempo de treinamento (min)	Memória utilizada (GB)
QLoRA	286,83	47,57
LoRA	276,46	59,91

Tabela 4. Métricas de treinamento para a etapa final do projeto. Fonte: Autoria própria.

4. Conclusão

Os resultados apresentados constatarem que o *fine-tuning* do modelo LLaMA-3.2-11B pode ser feito de forma eficiente através do treinamento com QLoRA. Os modelos treinados com este método obtiveram um desempenho semelhante ao dos modelos treinados com LoRA e requisitaram menos memória durante o treinamento.

Os resultados da etapa final foram poucos satisfatórios quanto ao critério de classificação de lesões, atingindo apenas 45,2% de acurácia após o treinamento com QLoRA. Embora o volume de dados utilizado nesta etapa tenha sido similar, com um total de 4736 pares de imagem e texto de resposta. O volume de dados no conjunto de treinamento pode ter sido insuficiente para o *fine-tuning*, impossibilitando os modelos finais de realizarem uma tarefa complexa como a geração de laudos com classificações e recomendações. Além do volume insuficiente, o desbalanceamento do conjunto de dados, caracterizado pela raridade de algumas lesões, pode ter impactado os modelos treinados, levando a um desempenho inferior na classificação de lesões com poucas ocorrências no conjunto de dados. Outro aspecto negativo do conjunto foi a variabilidade dentro de algumas classes de lesões, com classes como “Outras”, que não definem com precisão a lesão

apresentada na imagem. O grande volume de classes incertas pode ter levado ao baixo desempenho observado nas tarefas de classificação.

O desempenho na geração dos textos de conclusão na etapa final foi razoavelmente satisfatório, porém, alguns problemas foram identificados, como erros ortográficos e formatações não ideais. Essas características também são provenientes de inconsistências e erros no conjunto de dados.

4.1. Trabalhos Futuros

Considerando os resultados e limitações constatadas neste projeto, propõe-se a construção de um novo conjunto de dados com um maior volume e consistência entre as classes. Seria necessário incluir também uma nova classe referente a casos saudáveis, pois atualmente o modelo passa pelo *fine-tuning* para classificar somente diferentes lesões de pele, desconsiderando a possibilidade da ausência de lesões.

Recomenda-se também a otimização aprofundada dos hiperparâmetros de treinamento, possivelmente com técnicas de busca em grade.

A utilização de outros MLLMs também é recomendada, particularmente a do Gemma 3 de Kamath et al. (2025). Isso tornaria possível a realização de uma comparação mais avançada entre os diferentes modelos.

Por fim, sugere-se a utilização de avaliações manuais sobre partes dos resultados dos testes. Atualmente, os resultados são analisados de forma automática, o que pode levar à desconsideração de aspectos importantes do texto gerado. Com a participação de dermatologistas qualificados, seria possível avaliar o conteúdo destes textos de forma mais aprofundada.

Referências

DUBEY, Abhimanyu et al. The llama 3 herd of models. **arXiv preprint arXiv:2407.21783**, 2024.

FILGUEIRAS, Andréa Sabino; SILVA, Ana Lúcia Abrahão. Agente Comunitário de Saúde: um novo ator no cenário da saúde do Brasil. **Physis: Revista de Saúde Coletiva**, SciELO Public Health, v. 21, p. 899–916, 2011.

HABIF, Thomas P. **Clinical dermatology E-book**. [S.l.]: Elsevier Health Sciences, 2015. p. 1–19.

KAMATH, Aishwarya et al. Gemma 3 technical report. **arXiv preprint arXiv:2503.19786**, 2025.

LIMA VAZQUEZ, Vinicius de et al. Melanoma characteristics in Brazil: demographics, treatment, and survival analysis. **BMC Research Notes**, 2015. DOI: 10.1186/s13104-015-0972-8.

MAUAD, Edmundo C et al. Opportunistic screening for skin cancer using a mobile unit in Brazil. **BMC Dermatology**, 2011. DOI: 10.1186/1471-5945-11-12.

MINISTÉRIO DA SAÚDE. **Câncer de pele**. [S.l.: s.n.], 2020. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/c/cancer-de-pele>. Acesso em: 23 jun. 2024.

PANAGOULIAS, Dimitrios P.; VIRVOU, Maria; TSIHRINTZIS, George A. Evaluating LLM – Generated Multimodal Diagnosis from Medical Images and Symptom Analysis, 2024. DOI: 10.48550/arXiv.2402.01730.

PEFT. **PEFT**. [S.l.: s.n.], 2021. Disponível em: <https://huggingface.co/docs/peft>. Acesso em: 23 jun. 2024.

SANTOS, José Alcides Figueiredo. Desigualdades e interações de classe social na saúde no Brasil. **Dados**, SciELO Brasil, v. 63, n. 1, e20180104, 2020.

YOUL, Philippa H. et al. Association between melanoma thickness, clinical skin examination and socioeconomic status: Results of a large population-based study. **International Journal of Cancer**, v. 128, n. 9, p. 2158–2165, 2011. DOI: <https://doi.org/10.1002/ijc.25540>.