

Fine-tuning do MLLM LLaMA para a Classificação de Lesões de Pele e Geração de Laudos

Eric Fernandes Evaristo¹, Aldo von Wangenheim¹, Rodrigo de Paula e Silva Ribeiro¹

¹Departamento de Informática e Estatística
Centro Tecnológico – Universidade Federal de Santa Catarina (UFSC)

Resumo. A detecção precoce de lesões de pele é crucial para o tratamento de doenças graves, como o câncer de pele, mas o diagnóstico destas lesões requer um dermatologista. No Brasil, os Agentes Comunitários de Saúde (ACS) têm contato direto com a população, porém não possuem a qualificação necessária para realizar a triagem de lesões de pele. Diante disso, uma ferramenta que pudesse classificar essas lesões e fornecer pré-diagnósticos seria de grande auxílio. Neste contexto, os Multimodal Large Language Models (MLLMs) se mostram promissores, pois possuem a capacidade de interpretar imagens e gerar dados textuais.

Este trabalho avaliou o uso do Large Language Model Meta AI (LLaMA) 3.2 11B, para classificar lesões de pele e gerar laudos. Os experimentos foram divididos em duas etapas, com o fine-tuning sendo realizado em conjuntos de dados diferentes em cada uma delas. Na primeira etapa, usando o conjunto de dados de dermatoscopia Human Against Machine with 10000 training images (HAM10000) apenas para classificação, o modelo alcançou uma acurácia de 86,2% com Low-Rank Adaptation (LoRA). Enquanto na segunda etapa, que visava a classificação e a geração de laudos com um conjunto de dados proveniente do Sistema Integrado Catarinense de Telemedicina e Telessaúde (STT/SC), o desempenho caiu significativamente, com o modelo atingindo uma acurácia de 45,2% com Quantized Low-Rank Adaptation (QLoRA) e 44,5% com LoRA. O baixo desempenho dos modelos finais na classificação pode ser explicado por inconsistências no conjunto de dados.

Palavras-chave: Lesões de pele. Câncer de pele. MLLM. LLaMA. PEFT. Fine tuning. QLoRA. LoRA.

Abstract. Early detection of skin lesions is crucial for treating serious diseases, such as skin cancer, but the diagnosis of these lesions requires a dermatologist. In Brazil, Agentes Comunitários de Saúde (ACS) have direct contact with the population, however, they do not have the necessary qualifications to perform skin lesion screenings. Therefore, a tool that could classify these lesions and provide pre-diagnoses would be of great help. In this context, Multimodal Large Language Models (MLLMs) are promising, as they have the ability to interpret images and generate textual data.

This work evaluated the use of the Large Language Model Meta AI (LLaMA) 3.2 11B to classify skin lesions and generate reports. The experiments were divided into two stages, with fine-tuning performed on different datasets in each. In the first stage, using the Human Against Machine with 10000 training images (HAM10000) dermatoscopy dataset for classification only, the model

achieved an accuracy of 86.2% with Low-Rank Adaptation (LoRA). In the second stage, which aimed at classification and report generation with a dataset from the Sistema Integrado Catarinense de Telemedicina e Telessaúde (STT/SC), the performance dropped significantly, with the model reaching an accuracy of 45.2% with QLoRA and 44.5% with LoRA. The low classification performance of the final models can be explained by inconsistencies in the dataset.

Keywords: Skin lesions. Skin cancer. MLLM. LLaMA. PEFT. Fine-tuning. QLoRA. LoRA.

1. Introdução

Lesões de pele são áreas anormais ou danificadas da pele, causadas por diversos fatores, como condições ambientais, infecções ou doenças graves, incluindo o câncer de pele. A identificação precisa da causa é fundamental para o tratamento adequado, porém, devido à semelhança entre os sintomas, o diagnóstico correto das doenças de pele pode ser uma tarefa complexa. Além disso, o prognóstico pode se agravar significativamente se o tratamento não for iniciado cedo o suficiente (HABIF, 2015).

A importância do cuidado com lesões de pele é evidenciada pelo impacto do câncer de pele. No Brasil, 30% dos tumores malignos registrados são atribuídos a essa doença (MINISTÉRIO DA SAÚDE, 2020). Os tipos mais comuns, o carcinoma basocelular e o carcinoma epidermoide, apresentam baixa letalidade, mas podem deixar sequelas significativas devido ao tratamento. Já o melanoma, embora menos frequente, é altamente letal e corresponde a cerca de 75% das mortes causadas pelo câncer de pele (MAUAD et al., 2011). A detecção precoce é essencial para a eficácia do tratamento, pois a taxa de sobrevivência dos pacientes tende a cair com o avanço da doença (LIMA VAZQUEZ et al., 2015).

A dificuldade da identificação precoce de lesões de pele tem um componente socioeconômico. Em um estudo feito por Youl et al. (2011), observa-se que indivíduos com um grau menor de escolaridade têm um prognóstico pior, pois apresentam tumores em estágios mais avançados. Esta correlação pode indicar que a desigualdade resulta no atraso do diagnóstico e consequentemente na redução da taxa de sucesso do tratamento. Santos (2020) também constata que a saúde dos brasileiros está associada à renda e classe econômica.

No Brasil, uma parte da atenção primária é feita por ACS, que possuem um treinamento básico para atender a população e fornecer orientações básicas de saúde. Esses são os profissionais que normalmente estão em contato com as regiões mais carentes. A identificação da causa de uma lesão de pele está além das responsabilidades de um ACS (FILGUEIRAS; SILVA, 2011). Isso pode ser problemático, pois a triagem de um caso de lesão de pele requer a análise de um dermatologista, que nem sempre está disponível em regiões carentes.

Considerando este cenário, seria útil um serviço com boa usabilidade que analisasse imagens de pacientes e recomendasse uma forma de triagem, de modo a mitigar a carência por dermatologistas. As capacidades de classificar e descrever imagens com precisão tornam os MLLMs bons candidatos para fundamentar tal serviço (PANAGOULIAS; VIRVOU; TSIHRINTZIS, 2024).

Neste trabalho, o LLaMA-3.2-11B foi escolhido como modelo base para o desenvolvimento por ser de código aberto e por sua relevância no estado da arte para tarefas visuais e textuais (DUBEY et al., 2024). O modelo foi submetido ao *fine-tuning* com diferentes técnicas de treinamento ao longo de duas etapas, nas quais se utilizaram os conjuntos de dados HAM10000 e STT/SC para adaptá-lo às tarefas de classificação de lesões de pele e geração de laudos.

Com o objetivo de utilizar eficientemente os recursos computacionais disponíveis, o *fine-tuning* foi realizado com técnicas baseadas em *Parameter-Efficient Fine-Tuning* (PEFT). Este método permite a redução do número de parâmetros treinados, resultando em um menor consumo de recursos (PEFT, 2021). Especificamente, utilizaram-se os métodos QLoRA e LoRA para o treinamento do modelo.

1.1. Objetivos

O objetivo principal deste trabalho é treinar um *Large Language Model* (LLM) multimodal com métodos de *fine-tuning* para a classificação de lesões de pele e geração de laudos, avaliando o desempenho dos modelos resultantes e comparando as diferentes técnicas de treinamento.

Objetivos Específicos

- Realizar o *fine-tuning* do modelo LLaMA-3.2-11B com as técnicas de treinamento QLoRA e LoRA;
- Comparar os modelos resultantes do processo de *fine-tuning* com o LLaMA-3.2-11B;
- Comparar os modelos resultantes entre si a fim de avaliar o impacto das diferentes técnicas de treinamento.

1.2. Organização do Trabalho

O trabalho apresentará inicialmente os conceitos teóricos sobre lesões de pele e MLLMs, abordando a arquitetura e o treinamento destes modelos. Em seguida, serão apresentados e discutidos os trabalhos correlatos. Posteriormente, as duas etapas do desenvolvimento serão detalhadas, incluindo seus aspectos técnicos, treinamentos e resultados. Em sequência, os dados obtidos serão analisados e avaliados. Por fim, serão apresentadas as conclusões e os possíveis trabalhos futuros.

2. Fundamentação Teórica

Neste capítulo, serão apresentados os aspectos teóricos de lesões de pele, MLLMs, variantes do modelo LLaMA-3.2 e de técnicas de *fine-tuning*. O funcionamento e desenvolvimento de MLLMs serão esclarecidos com a explicação dos principais componentes desses modelos.

2.1. Lesões de Pele

A pele é o maior órgão do corpo humano e é responsável por proteger o corpo de agentes microbiológicos, físicos e químicos. Além disso, ela também ajuda na regulação da temperatura do corpo e, através de receptores cutâneos, proporciona informações sensoriais como o tato (JABLONSKI, 2004).

Devido à exposição da pele ao ambiente, é mais comum que esse órgão sofra com doenças. As áreas afetadas são consideradas lesões de pele e podem ser usadas para diagnósticos de doenças (SUMITHRA; SUHIL; GURU, 2015).

Muitas doenças de pele se manifestam como lesões básicas que podem ser chamadas de lesões primárias. Vários fatores influenciam no diagnóstico de uma doença de pele, Habif (2015) recomenda que sejam considerados aspectos como o histórico da lesão, distribuição, características visuais e testes laboratoriais. Porém, o diagnóstico de uma doença de pele ainda é desafiador. Uma mesma doença de pele pode apresentar diferentes sintomas em cada instância e também pode evoluir ao longo do tempo. A análise visual é o principal componente no diagnóstico de lesões de pele, nesse processo, a lesão é analisada pelas suas características superficiais, como a cor, textura e presença de certas estruturas.

2.1.1. Imagens de Lesões de Pele

O caráter visual da análise de lesões de pele permite que imagens sejam utilizadas em exames dermatológicos. Essas imagens podem ser agrupadas em diferentes categorias. Alguns exemplos baseados em procedimentos recomendados por Von Wangenheim, Wagner e Nogueira (2013) são:

- **Dermatoscopia:** Estas imagens são obtidas com um equipamento especializado, o dermatoscópio. Esse método permite que um diagnóstico mais preciso seja feito, sendo melhor que o olho nu na detecção de melanomas (BONO et al., 2002);
- **Foto de aproximação com régua:** Esse tipo de imagem é obtida com uma fotografia feita a 30 centímetros da lesão, sem utilizar *zoom*. Nessas imagens, etiquetas são colocadas próximas à lesão para auxiliar na determinação do seu tamanho;
- **Foto panorâmica:** Nesse método são registradas imagens de regiões do corpo, como da cabeça, tronco, braços e pernas.



Figura 1. Exemplo de um exame de dermatoscopia, aproximação e panorâmica da cabeça, respectivamente. Fonte: Von Wangenheim, Wagner e Nogueira (2013).

2.2. Multimodal Large Language Models

MLLMs são Inteligências Artificiais (IAs) baseadas em LLMs que possuem a capacidade de interpretação de diferentes modalidades de informação, como imagens, vídeos e

áudios. O que torna esses modelos diferentes de LLMs, que operam sobre informações textuais. Esses modelos também podem ser capazes de gerar conteúdo (YIN et al., 2023; ZHANG, D. et al., 2024).

Segundo Duzhen Zhang et al. (2024), a estrutura de um MLLM pode ser dividida em cinco componentes, sendo eles o codificador de modalidade, projetor de entrada, LLM, projetor de saída e o gerador de modalidade. No caso de MLLMs que possuem apenas saída de texto, somente os três primeiros componentes estão presentes, essa estrutura é demonstrada na Figura 2.




Figura 2. Estrutura de um MLLM que realiza apenas a interpretação multimodal.
Fonte: Autoria própria.

2.2.1. *Large Language Models*

LLMs ou Grandes Modelos de Linguagem são modelos estatísticos pré-treinados baseados em transformadores que possuem bilhões de parâmetros e conseguem processar e gerar textos em linguagem natural (MINAEE et al., 2024).

Embora modelos de linguagem já sejam conceitos discutidos há várias décadas, a introdução da arquitetura de transformadores no artigo *Attention Is All You Need* de Vaswani et al. (2017) define um marco no desenvolvimento destes modelos, levando ao surgimento de LLMs.

O funcionamento desta arquitetura pode ser explicada em diversas etapas. Inicialmente, antes do processamento no transformador, o texto é dividido em partes menores, chamadas *tokens*, no processo de tokenização. Geralmente, essas partes se consistem de palavras ou partes de palavras. No transformador, os *tokens* são então representados em incorporações vetoriais, que se tratam de vetores em um espaço n-dimensional. Essas incorporações passam pela codificação posicional, definindo as suas posições na sequência. Após a codificação posicional, os vetores passam pelas camadas do transformador.

Na arquitetura original, o transformador possui um codificador e um decodificador, sendo que cada um deles é composto por camadas diferentes. No codificador, cada camada é composta por duas subcamadas, sendo uma delas um mecanismo de *multi-head*

self-attention e outra, uma rede *feed-forward*. A saída de cada uma delas possui uma conexão residual e uma etapa de normalização. O decodificador é similar ao codificador, mas suas camadas possuem uma subcamada extra que aplica o mecanismo de *multi-head self-attention* mascarado sobre a saída do codificador. Além disso, a entrada do decodificador é deslocada em uma posição, de modo que uma nova incorporação possa ser prevista e usada para gerar um *token*. A Subsubseção 2.2.1 mostra o transformador original.




Figura 3. Arquitetura de um transformador. Fonte: Vaswani et al. (2017).

2.2.2. Codificador de Modalidade

Codificadores de modalidade são os componentes responsáveis pela extração das características mais relevantes dos dados multimodais de entrada em incorporações vetoriais (ZHANG, D. et al., 2024). Um exemplo de codificador de modalidade é o codificador visual, do qual existem várias implementações. Os mais comuns usam *Vision Transformers* (ViTs) ou Transformadores Visuais nas suas arquiteturas, mas também há codificadores baseados em convolução, como o *Osprey* (YIN et al., 2023).

ViTs são transformadores capazes de processar imagens introduzidos por Dosovitskiy (2020). A arquitetura original utiliza apenas codificadores e visa classificar imagens. O funcionamento desse tipo de transformador é similar ao do modelo de Vaswani et al. (2017), com a tokenização de imagens em seções menores e a representação dessas seções em incorporações vetoriais. A Subsubseção 2.2.2 demonstra a estrutura de um transformador visual com os detalhes de sua implementação.




Figura 4. Transformador visual. Fonte: Dosovitskiy (2020).

2.2.3. Projetor de Entrada

Esse componente faz o alinhamento entre o espaço de incorporações geradas pelo codificador e o espaço de incorporações do LLM, podendo utilizar um *Multilayer perceptron* (MLP) ou um mecanismo de *cross-attention*. A principal diferença de *cross-attention* para *self-attention* nesse contexto está no uso dos vetores de *key* provenientes do codificador para o cálculo da atenção no transformador do LLM (ZHANG, D. et al., 2024).

2.2.4. Pré-treinamento e *Fine-tuning*

O pré-treinamento de um MLLM envolve um grande volume de dados e poder computacional, sendo particularmente intensivo na parte de treinamento do LLM (ZHANG, D. et al., 2024). Em geral, o modelo resultante deste processo é generalista e não foca em nenhum domínio de conhecimento em particular.

O *fine-tuning* é uma etapa de treinamento que pode ser realizada para melhorar o desempenho do modelo com relação a dados específicos ou sobre um domínio de conhecimento. Técnicas de *fine-tuning* eficientes, como as baseadas em PEFT, oferecem uma forma de adaptação de modelos com um custo computacional relativamente menor. Dentre várias técnicas, uma das mais populares é o treinamento com LoRA (ZHANG et al., 2023).

A técnica LoRA, proposta por Edward J Hu et al. (2021), consiste-se em explorar o *rank* intrínseco, um conceito baseado em dimensionalidade intrínseca, introduzindo matrizes treináveis menores de baixo *rank* ao MLLM, deixando as matrizes originais intactas durante o treinamento. Assim que treinadas, essas matrizes são adicionadas às originais.

O *rank* de uma matriz é o número de colunas ou linhas linearmente independentes que a matriz possui. Ele também corresponde à dimensão do espaço vetorial gerado pelas colunas ou linhas. O *rank* intrínseco se trata do menor *rank* que a matriz pode ter no treinamento sem haver uma grande perda de desempenho.

Assim, pode-se resumir que com base em uma matriz W_0 do modelo, tal que $W_0 \in \mathbb{R}^{d \times k}$, é possível representá-la em uma forma decomposta $W_0 + \Delta W$ em que $\Delta W = BA$, tal que $B \in \mathbb{R}^{d \times r}$ e $A \in \mathbb{R}^{r \times k}$, sendo que $r \ll \min(d, k)$. A matriz W_0 é travada enquanto as matrizes A e B são treináveis. A matriz A é inicializada com uma distribuição gaussiana aleatória e a B é inicializada como zero. Na Subsubseção 2.2.4 é apresentada uma representação visual do LoRA com a expressão $h = W_0x + BAx$.




Figura 5. Representação do LoRA com as matrizes W_0 , A e B . Fonte: Edward J Hu et al. (2021).

É comum utilizar quantização para acelerar o *fine-tuning*, onde se reduz precisão numérica durante o treinamento. Uma técnica que utiliza este conceito é o QLoRA, proposta por Dettmers et al. (2024). Nela, é usado o tipo *4-bit Normal Float* (NF4) no armazenamento das matrizes pré-treinadas, sendo que os valores em NF4 são convertidos para *16-bit Brain Floating point* (BF16) durante os cálculos. Além disso, também são usados otimizadores paginados e dupla quantização.

2.3. LLaMA 3

A família de modelos LLaMA-3 é composta por LLMs e MLLMs desenvolvidos pelos pesquisadores da *Meta AI*. Em particular, este trabalho focará no modelo multimodal LLaMA-3.2, que possui as variantes com 11 (LLaMA-3.2-11B) e 90 (LLaMA-3.2-90B) bilhões de parâmetros disponíveis (DUBEY et al., 2024).

O LLM base do LLaMA-3.2 utiliza um transformador decodificador que possui algumas diferenças em relação à arquitetura original de Vaswani et al. (2017), as maiores diferenças já existem desde os modelos LLaMA e LLaMA-2 e podem ser elencadas com base no trabalho de Touvron et al. (2023):

- **Pré-normalização:** As subcamadas são pré-normalizadas, em vez de serem normalizadas posteriormente;
- **Normalização:** A função de normalização usada é a *Root Mean Square Layer Normalization* (RMSNorm);
- **Função de ativação:** Na subcamada de *feed-forward*, a função de ativação é a *Swish-Gated Linear Unit* (SwiGLU), em vez de *Rectified Linear Unit* (ReLU);
- **Codificação posicional:** A codificação posicional é feita com *Rotary Positional Embeddings* (RoPE), em vez da codificação absoluta;
- **GQA:** *Grouped Query Attention* (GQA) é utilizado com 8 cabeças de chave-valor para melhorar a velocidade de inferência e reduzir o tamanho dos *caches* de chave-valor durante a decodificação;

- **Máscara de atenção:** Uma máscara é utilizada para impedir o relacionamento entre diferentes documentos de uma mesma entrada;
- **Vocabulário:** O vocabulário de *tokens* usado possui 128 mil *tokens*.

A Subseção 2.3 apresenta alguns parâmetros das variantes do LLM.

	8B	70B	450B
Camadas do transformador	32	80	126
Dimensão das incorporações	4096	8192	16384
Dimensão da rede <i>feed-forward</i>	14336	28672	53248
<i>fAttention heads</i>	32	64	128
<i>fKey / Value heads</i>	8	8	8
Taxa máxima de aprendizado	3×10^{-4}	1.5×10^{-4}	8×10^{-5}
Função de ativação	SwiGLU		
Tamanho do vocabulário	128000		
Codificação posicional	RoPE($\theta = 500000$)		

Tabela 1. Características das variantes do LLaMA-3. Fonte: Dubey et al. (2024).

O codificador visual utilizado é baseado no transformador visual de Dosovitskiy (2020), sendo usada a variante ViT-H/14 com modificações extras, como a adição de extração de características multicamadas e de 8 camadas de *gated self-attention*, deixando o codificador com um total de 850 milhões de parâmetros.

O projetor de entrada, referenciado como adaptador de visão no trabalho de Dubey et al. (2024), se baseia em *cross-attention* entre as camadas de codificação do codificador visual e as camadas de decodificação do LLM. Mais especificamente, é aplicada uma camada de *cross-attention* a cada quarta camada do LLM. Essas camadas também utilizam GQA para melhorar o desempenho.

Além de imagens, o LLaMA-3.2 também pode operar com vídeos e áudios. A Tabela 2.3 apresenta a arquitetura multimodal do modelo.




Figura 6. Arquitetura multimodal de imagem e vídeo do LLaMA-3.2. Fonte: Dubey et al. (2024).

3. Trabalhos Correlatos

Nos últimos anos, a aplicação de MLLMs na análise de imagens médicas se tornou mais comum. Em uma revisão sistemática de Evaristo et al. (2025), é avaliado o estado da arte, contemplando os principais avanços e desafios nesta área. Em geral, a maioria dos MLLMs que possuem alguma capacidade de análise de imagens dermatológicas são generalistas e não apresentam uma avaliação aprofundada de suas capacidades de classificação ou descrição de lesões de pele. Porém, há modelos especializados para a dermatologia, como o SkinGPT-4 de Zhou, He et al. (2023). Nas subseções abaixo, serão apresentados alguns modelos que possuem aplicações na dermatologia.

3.1. SkinGPT-4

O modelo SkinGPT-4 foi proposto e desenvolvido por Zhou, He et al. (2023) e se baseia no *MiniGenerative Pre-trained Transformer (GPT)-4*, um MLLM composto por um ViT com um *Q-Former* pré-treinado e o LLM Vicuna, que por sua vez é baseado no LLaMA. Este MLLM foi desenvolvido para tarefas de pergunta e resposta visuais, também conhecidas como *Visual Question Answering (VQA)*. A arquitetura pode ser vista na Subseção 3.1.




Figura 7. Arquitetura do SkinGPT-4. Fonte: Zhou, He et al. (2023).

Neste estudo, o MiniGPT-4 passou por um processo de *fine-tuning* de duas etapas que familiarizou o modelo com imagens de lesões de pele e depois ajustou suas saídas para um formato mais próximo de um diagnóstico médico. As imagens vieram de um conjunto de dados particular, do SKINCON e do Dermnet, sendo que 3886 imagens foram usadas na primeira etapa de treinamento e 49043 na segunda.

A verificação do desempenho do modelo foi feito com base em 150 diagnósticos de casos reais realizados pelo SkinGPT-4. Esses diagnósticos foram avaliados por dermatologistas certificados, sendo que 78,76% dos diagnósticos foram classificados como corretos.

3.2. MpoxVLM

O modelo MpoxVLM de Cao et al. (2024) é um MLLM direcionado ao diagnóstico de lesões de pele causadas pela doença *Monkeypox*. O modelo possui dois codificadores visuais, um deles é o *Contrastive Language-Image Pre-training* (CLIP) ViT-L/14 e o outro é o ViT-L/14-336 pré-treinado para a classificação de lesões de pele. Um MLP de duas camadas é usado como projetor de entrada para o codificador CLIP, sendo que a saída do codificador ViT, a classe da lesão de pele, é enviada para outro projetor de entrada. O LLaMA-2 é usado como LLM, especificamente a variante com 7 bilhões de parâmetros. A Subseção 3.2 apresenta a arquitetura deste MLLM.




Figura 8. Arquitetura do MpoxVLM. Fonte: Cao et al. (2024).

Inicialmente, o ViT-L/14-336 foi pré-treinado com o conjunto de dados de lesões de pele causadas por *Monkeypox*. Depois o modelo foi construído e os projetores de entrada foram treinados. Por fim, foi feito um *fine-tuning* com LoRA do LLaMA-2 para tarefas de VQA. Foram utilizadas duas NVIDIA RTX 4090 para os treinamentos neste estudo.

Os resultados apresentados demonstram que o MpoxVLM atinge uma acurácia de 90,38% no diagnóstico de *Monkeypox*, ultrapassando vários outros MLLMs.

3.3. MedPLIB

O MedPLIB de Huang et al. (2024) é um MLLM generalista que foca no entendimento de imagens a nível de pixel, oferecendo suporte para vários formatos de *prompt*, como os de VQA e de descrição de regiões ou pontos. O modelo utiliza o codificador visual CLIP Large de Radford et al. (2021), o LLM LLaMA-2 com 7 bilhões de parâmetros e o modelo para segmentação de imagens **sam-med2d!** (**sam-med2d!**) de Cheng et al. (2023) como decodificador para o foco em áreas específicas da imagem.

A arquitetura do MedPLIB é organizada como uma *Mixture of Experts* (MoE), dessa forma, múltiplos modelos são treinados com focos em diferentes domínios, levando ao aumento do desempenho. O *fine-tuning* foi realizado em quatro estágios, começando com o alinhamento das respostas textuais e seguindo com o treinamento visual para o VQA. Depois, o decodificador utilizado na segmentação e identificação de regiões foi treinado e o processo foi finalizado com um treinamento completo sobre todos os componentes do modelo. A Subseção 3.3 apresenta a arquitetura do MedPLIB.




Figura 9. Arquitetura do MedBLIP. Fonte: Huang et al. (2024).

O estudo apresenta avaliações na área da dermatologia com o *benchmark* Omni-MedVQA de Yutao Hu et al. (2024), que avalia o desempenho em tarefas de VQA. Os resultados podem ser conferidos na Figura 3.3.

Modelo	Pontuação
MiniGPT-4	41,28
BLIP-2	40,93
InstructBLIP	63,02
<i>Large Language and Vision Assistant (LLaVA)</i>	49,67
VPGLTrans	45,42
RadFM	38,32
LLaVA-Med	46,42
LISA	41,61
MedPLIB (sem MoE)	43,37
MedPLIB	51,47

Tabela 2. Comparação entre modelos no *benchmark* OmniMedVQA em dermatologia. A pontuação máxima está destacada. Fonte: Yutao Hu et al. (2024).

3.4. UMed-LVLM

O modelo UMed-LVLM, desenvolvido por Zhou, Song e Shen (2025), é generalista e foca em aprimorar a capacidade de localização de anormalidades médicas em imagens. Este modelo baseia-se no MedVInt de Xiaoman Zhang et al. (2023) e é treinado em duas etapas, sendo que a primeira realiza um *fine-tuning* com o método *Abnormal-Aware Instruction Tuning* e a segunda aplica *Proximal Policy Optimization* (PPO) com o método *Abnormal-Aware Rewarding*.




Figura 10. Processo de treinamento do UMed-LVLM. Fonte: Zhou, Song e Shen (2025).

O artigo apresenta a avaliação da acurácia em diagnósticos dermatológicos do UMed-LVLM. Os testes foram realizados com o conjunto de dados MedMNIST de Yang, Shi e Ni (2021). A Figura 3.4 traz os resultados da avaliação.

Modelo	Acurácia
ResNet50	73,1
DWT-CV	74,8
SADAE	75,9
PMC-CLIP	79,8
MedVInT	80,0
UMed-LVLM	84,1

Tabela 3. Comparação entre modelos com a seção de dermatologia do conjunto de dados MedMNIST. A pontuação máxima está destacada em negrito. Fonte: Zhou, Song e Shen (2025).

3.5. UMIT

UMIT é um MLLM generalista desenvolvido por Yu et al. (2025) que tem como objetivo suportar VQA em várias áreas da medicina. O modelo foi treinado a partir do MLLM Qwen2-VL de Wang et al. (2024) e utilizou um regime de duas etapas no seu treinamento. A primeira etapa alinhou as informações das imagens médicas com as informações textuais. Na segunda etapa, o *fine-tuning* do modelo foi realizado, adaptando-o para diversas tarefas de VQA. A Subseção 3.5 mostra a arquitetura e o processo de treinamento do modelo UMIT.




Figura 11. (a): Processo de treinamento e arquitetura do UMIT. (b) Primeira etapa de treinamento (c): Segunda etapa de treinamento. Fonte: Yu et al. (2025).

A acurácia do modelo em diagnósticos foi avaliada com a seção de dermatologia do conjunto de dados MedMNIST e pode ser conferida na Figura 3.5.

Modelo	Acurácia
Qwen2-vl	11,3
BiomedGPT-S	75,2
BiomedGPT-M	78,0
BiomedGPT-B	78,6
UMIT	82,54

Tabela 4. Comparação da acurácia entre modelos na categoria de dermatologia do MedMNIST. A pontuação máxima está destacada. Fonte: Yu et al. (2025).

3.6. Comparação entre MLLMs

Os MLLMs avaliados apresentam arquiteturas diversas e baseiam-se em modelos pré-treinados de código aberto. O *fine-tuning* de múltiplas etapas foi frequentemente utilizado. Dos cinco modelos apresentados, somente o SkinGPT-4 e o MpoxVLM são especializados em lesões de pele, sendo que o estudo que propõe o modelo SkinGPT-4 é o que tem o objetivo mais similar ao deste trabalho. Porém, o conjunto de dados utilizado para o treinamento do SkinGPT-4 é diverso e possui imagens de diferentes categorias, como imagens macroscópicas e imagens de exames de dermatoscopia. Comparativamente, o modelo final deste trabalho opera sobre imagens macroscópicas, especificamente, imagens de aproximação.

Devido à introdução relativamente recente da família de modelos LLaMA-3, há poucos estudos que utilizam esses MLLMs. Um diferencial considerável deste trabalho é a utilização do LLaMA-3.2-11B como modelo base. Além disso, outro diferencial é a análise comparativa do QLoRA em relação ao LoRA no contexto do treinamento de modelos para a classificação de lesões de pele e geração de laudos. Por fim, a Subseção 3.6 apresenta uma comparação entre os MLLMs apresentados.

Modelo	MLLM ou arquitetura base
SkinGPT-4	MiniGPT-4
MpoxVLM	CLIP, ViT-L/14-336 e LLaMA-2-7B
MedPLIB	CLIP-Large, sam-med2d! e LLaMA-2-7B (MoE)
UMed-LVLM	MedVInt
UMIT	Qwen2-VL
MLLM deste trabalho	LLaMA-3.2-11B

Tabela 5. Comparação entre os diferentes MLLMs focados na área médica e na classificação de lesões de pele. Fonte: Autoria própria.

4. Desenvolvimento

Esta seção apresentará as duas etapas do desenvolvimento do trabalho. Para cada etapa, será apresentado o processo de treinamento e de execução de testes, incluindo também a análise dos resultados.

4.1. Tecnologias Utilizadas

Para ambas as etapas, as mesmas tecnologias foram utilizadas. O processamento de dados e *fine-tuning* foram feitos com *scripts* em Python 3.10 e *Jupyter notebooks*. O gerenciador Poetry foi utilizado para gerenciar as dependências e o *framework* Unsloth foi utilizado no *fine-tuning*. Por fim, os treinamentos foram realizados com uma placa NVIDIA H100 de 80 GB que faz parte de uma plataforma NVIDIA DGX H100.

4.2. Etapa Inicial de Desenvolvimento

Nesta etapa, o LLaMA-3.2-11B passou pelo *fine-tuning* para classificar imagens de lesão de pele advindas de exames de dermatoscopia. A etapa inicial demonstra um caráter exploratório que visa o desenvolvimento do código base para os próximos experimentos e também analisa a capacidade de classificação do modelo quando treinado de diferentes formas.

4.2.1. Conjunto de Dados

Para os experimentos iniciais, utilizou-se o conjunto de dados HAM10000 de Tschandl, Rosendahl e Kittler (2018), que possui 13354 imagens de dermatoscopia com resolução de 600×450 pixels. São associadas às imagens informações como a doença causadora da lesão de pele, a idade do paciente, sexo e localização da lesão.

Optou-se pela não inclusão de outros conjuntos de dados com imagens de dermatoscopia no treinamento, como os do *International Skin Imaging Collaboration* (ISIC), devido à complexidade na adaptação do formato. O código desenvolvido foi idealizado para o conjunto de dados final, proveniente do STT/SC, tornando necessário o uso de um conjunto com formato próximo para o treinamento. Por fim, como as comparações foram realizadas com um volume relativamente pequeno de dados, o HAM10000 foi suficiente, eliminando a necessidade de outros conjuntos.

O conjunto de dados é separado nas seções de treinamento, teste e validação, que possuem 9577, 1285 e 2492 imagens, respectivamente. A Subsubseção 4.2.1 apresenta

as proporções entre as categorias de lesões de pele. Os dados foram obtidos a partir da plataforma Hugging Face com uma versão do HAM10000 fornecida por Low (2023). A proporção das lesões é conservada entre as seções do conjunto de dados.

Lesão de pele	Proporção (%)
Nevo melanocítico	66,88
Melanoma	11,23
Lesões similares à queratose benigna	10,94
carcinoma basocelular (CBC)	5,08
Queratose actínica	3,29
Lesões vasculares	1,42
Dermatofibroma	1,15

Tabela 6. Proporção entre as diferentes categorias de lesões de pele no HAM10000. Fonte: Tschandl, Rosendahl e Kittler (2018).

4.2.2. Estruturação dos Dados no Modelo Conversacional

Para treinar o modelo, foram gerados diálogos constituídos de um pedido para a classificação da lesão com base em uma imagem e de uma resposta com a classe da lesão. Os pares de imagens e lesões de pele foram selecionados a partir de amostras do conjunto de dados de treinamento. A amostragem foi feita com base nas classes das lesões de pele, assim, cada amostra possui uma representação proporcional das lesões em relação ao conjunto de dados completo.

O modelo utilizado não possui suporte nativo à utilização de textos em português para tarefas multimodais, sendo assim, os diálogos foram produzidos em inglês. O padrão de diálogo pode ser conferido abaixo:

Usuário: *Classify the skin lesion in the image. (imagem)*
Modelo: *The skin lesion in the image is (lesão de pele).*

4.2.3. Fine-tuning com 450 e 900 Amostras

A primeira etapa nos experimentos foi a realização o *fine-tuning* por meio do treinamento com QLoRA com 450 amostras de treinamento e 50 de validação. Os hiperparâmetros¹ utilizados no treinamento estão na Tabela 7, alguns deles foram omitidos por serem menos relevantes nessa etapa. O *rank-stabilized LoRA* (rsLoRA) de Kalajdzievski (2023) foi utilizado para melhorar o desempenho, utilizando um fator de escala $\frac{\alpha_{LoRA}}{\sqrt{r}}$ em vez do $\frac{\alpha_{LoRA}}{r}$ do LoRA original. Por fim, também foi utilizado o otimizador *Adaptive Moment Estimation* (Adam) na sua versão paginada de 32 bits. A primeira linha da Figura 4.2.3 inclui os dados sobre o treinamento e a Tabela 4.2.3 apresenta o *loss* de treinamento e validação ao longo dos passos.

¹parâmetros de treinamento

Hiperparâmetro	Valor
Camadas e módulos treinados	Visão, linguagem, atenção e MLP
<i>Rank</i>	32
Alfa (α_{LoRA})	32
Dropout	0,1
rsLoRA	Sim
Tamanho do lote por dispositivo	8
Passo de acumulação de gradiente	1
Taxa de aprendizado	2×10^{-4}
Razão de aquecimento	0,03
Escalonador da taxa de aprendizado	Cosseno com reinícios
Decaimento de peso	0,01
Épocas	5
Passos a cada validação	50
Otimizador	Adam paginado de 32 bits
Tipo numérico	BF16

Tabela 7. Hiperparâmetros para o QLoRA com 450 e 900 amostras. A primeira seção se refere às configurações específicas de PEFT, enquanto a segunda se refere ao treinamento em geral. Fonte: Autoria própria.




Figura 12. Loss de treinamento e validação para o QLoRA com 450 amostras.
Fonte: Autoria própria.

Em seguida, foi realizado o treinamento com LoRA, ou seja, sem quantização, com 450 amostras. Os hiperparâmetros utilizados são similares, porém, o *rank* foi reduzido para 16, assim como o α_{LoRA} . O rsLoRA não foi utilizado e a taxa de aprendizado foi reduzida a 1×10^{-4} . Por fim, o otimizador *Adam with decoupled weight decay* (AdamW) foi utilizado. A segunda linha da Figura 4.2.3 apresenta os dados de treinamento com LoRA e a Figura 4.2.3 apresenta o *loss*. O treinamento foi aplicado somente sobre 64174400 parâmetros, uma quantidade menor do que a usada no QLoRA por conta do *rank* reduzido.




Figura 13. Loss de treinamento e validação para o LoRA com 450 amostras.
Fonte: Autoria própria.

Método de treinamento	Parâmetros	Duração (min)	Passos	Memória (GB)
QLoRA	134348800	16,17	110	18,69
LoRA	64174400	26,42	140	40,35

Tabela 8. Dados sobre o treinamento com QLoRA e LoRA com 450 amostras.
Fonte: Autoria própria.

O *fine-tuning* com 900 amostras foi feito sem a alteração nos hiperparâmetros do QLoRA e LoRA. As informações sobre o treinamento podem ser conferidas na Tabela 4.2.3, enquanto o *loss* pode ser conferido na Tabela 4.2.3 e na Figura 4.2.3.

Método de treinamento	Parâmetros	Duração (min)	Passos	Memória (GB)
QLoRA	134348800	32,08	225	18,69
LoRA	67174400	41,76	280	31,96

Tabela 9. Dados sobre o treinamento com QLoRA e LoRA com 900 amostras.
Fonte: Autoria própria.




Figura 14. Loss de treinamento e validação para o QLoRA com 900 amostras.
Fonte: Autoria própria.




Figura 15. Loss de treinamento e validação para o LoRA com 900 amostras.
Fonte: Autoria própria.

4.2.4. Fine-tuning com 5000 Amostras

Os hiperparâmetros foram modificados para os treinamentos com 5000 amostras, assim, foi possível avaliar o impacto de diferentes configurações de treinamento. As configurações na Subsubseção 4.2.4 se referem tanto ao treinamento com QLoRA quanto ao com LoRA. Os dados dos treinamentos podem ser conferidos na Tabela 11, enquanto o *loss* pode ser conferido na Tabela 4.2.4 e Figura 4.2.4. Observa-se também que os hiperparâmetros utilizados levaram a uma maior instabilidade no *loss* ao longo dos passos.

Hiperparâmetro	Valor
Camadas e módulos treinados	Visão, linguagem, atenção e MLP
<i>Rank</i>	64
Alfa (α_{LoRA})	64
Dropout	0,05
rsLoRA	Sim
Tamanho do lote por dispositivo	8
Passo de acumulação de gradiente	1
Taxa de aprendizado	1×10^{-4}
Razão de aquecimento	0
Escalonador da taxa de aprendizado	Constante
Decaimento de peso	0,01
Épocas	3
Passos a cada validação	A cada 5% dos passos
Otimizador	Adam paginado de 32 bits
Tipo numérico	BF16

Tabela 10. Hiperparâmetros para o *fine-tuning* com 5000 amostras. A primeira seção se refere às configurações específicas de PEFT, enquanto a segunda se refere ao treinamento em geral. Fonte: Autoria própria.

Método de treinamento	Parâmetros	Duração (min)	Passos	Memória (GB)
QLoRA	268697600	96,63	1875	18,97
LoRA	268697600	100,33	1875	31,48

Tabela 11. Dados sobre o treinamento com QLoRA e LoRA com 5000 amostras. Fonte: Autoria própria.




Figura 16. Loss de treinamento e validação para o QLoRA com 5000 amostras.
Fonte: Autoria própria.




Figura 17. Loss de treinamento e validação para o LoRA com 5000 amostras.
Fonte: Autoria própria.

4.2.5. Testes

Os testes se consistiram de uma série de perguntas aos modelos, onde foram utilizadas duas modalidades de pergunta, uma livre e outra objetiva. Na pergunta livre o *prompt* é definido como:

Usuário: *Classify the skin lesion in the image. (imagem)*

Já na pergunta objetiva, é esperado que o modelo informe apenas o nome da doença com base nas opções possíveis do conjunto de dados, sendo que o *prompt* usado é:

Usuário: *Classify the skin lesion in the image. Say only the name of the disease and nothing else. The diseases to be classified are: melanocytic Nevi, melanoma, benign keratosis-like lesions, basal cell carcinoma, actinic keratoses, vascular lesions and dermatofibroma.(imagem)*

Foram feitas 100 perguntas livres e 1000 perguntas objetivas para cada modelo treinado e para o LLaMA-3.2-11B na versão quantizada e não quantizada. As imagens utilizadas vieram da seção de teste do conjunto de dados. A temperatura, uma variável que define a previsibilidade do modelo, foi definida como 0,1, reforçando a objetividade das respostas. Além disso, o número máximo de *tokens* foi definido como 128.

4.2.6. Análise do LLaMA-3.2-11B

Tanto o modelo na versão regular quanto o modelo quantizado apresentaram respostas bem variadas para cada pergunta livre. Em geral, as respostas apresentaram uma estrutura de passos que se baseia em metodologias de classificação de lesões de pele. O diálogo abaixo apresenta uma classificação correta para a imagem de um melanoma:

Usuário: *Classify the skin lesion in the image. (imagem de um melanoma)*
Modelo: *Step 1: Identify the lesion.*
The image shows a skin lesion with an irregular border and a dark brown color.
Step 2: Determine the characteristics of the lesion.
The lesion has an irregular border, which is a characteristic of melanoma. The dark brown color is also consistent with melanoma.
Step 3: Consider the possible diagnoses.
Based on the characteristics of the lesion, it is likely that the diagnosis is melanoma.
Step 4: Provide the final answer.
Answer: Melanoma

Muitas respostas apresentaram uma classificação incorreta, embora tenham sido descritivas sobre a lesão. No exemplo abaixo, o modelo classificou um nevo melanocítico como um melanoma:

Usuário: *Classify the skin lesion in the image. (imagem de um nevo melanocítico)*
Modelo: *Step 1: Identify the lesion*
The image shows a brown, irregularly shaped lesion with a darker brown border.
Step 2: Determine the characteristics of the lesion
The lesion is asymmetrical, has an irregular border, and has multiple colors.
Step 3: Classify the lesion
Based on the characteristics of the lesion, it is classified as a melanoma.
Answer: Melanoma

Algumas respostas não apresentaram uma classificação precisa, sendo que o modelo informou apenas que a imagem se tratava de uma lesão de pele. Um exemplo assim pode ser visto no diálogo abaixo:

Usuário: *Classify the skin lesion in the image. (imagem de um nevo melanocítico)*

Modelo: *The skin lesion in the image appears to be a dermatological condition, likely a type of skin cancer or a benign growth. However, without further information or a medical diagnosis, it is difficult to provide a definitive classification.*

Já nas respostas às perguntas objetivas, o modelo quantizado teve um desempenho levemente pior em relação ao não quantizado. Porém, ambos tiveram um desempenho pouco satisfatório, a versão quantizada atingiu apenas 11,8% de acurácia e a não quantizada atingiu 14%.

A Subsubseção 4.2.6 e a Figura 4.2.6 apresentam as matrizes de confusão normalizadas pelos valores verdadeiros para o modelo quantizado e o não quantizado, respectivamente. Nota-se que eles classificaram as lesões como melanoma em uma escala desproporcional, o LLaMA quantizado classificou 97,6% das lesões como melanoma, enquanto o não quantizado classificou 88,3%. Também pode-se notar uma tendência da classificação de lesões vasculares como dermatofibroma por parte do modelo não quantizado.

Foram registradas 3 respostas incertas para o modelo quantizado e apenas uma para o não quantizado.




Figura 18. Matriz de confusão para o LLaMA-3.2-11B quantizado. Fonte: Autoria própria.




Figura 19. Matriz de confusão para o LLaMA-3.2-11B não quantizado. Fonte: Autoria própria.

4.2.7. Análise dos Modelos após o *Fine-tuning*

Para as perguntas livres, todos os modelos treinados responderam no formato especificado no treinamento. O primeiro diálogo abaixo apresenta uma classificação correta e o segundo apresenta uma incorreta, ambas as respostas foram dadas pelo modelo treinado com QLoRA com 450 amostras:

Usuário: *Classify the skin lesion in the image. (imagem de um nevo melanocítico)*

Modelo: *The skin lesion in the image is melanocytic Nevi.*

Usuário: *Classify the skin lesion in the image. (imagem de um nevo melanoma)*

Modelo: *The skin lesion in the image is benign keratosis-like lesions.*

Os modelos treinados com QLoRA com 450 e 5000 amostras, e com LoRA com 5000 amostras apresentaram um problema em que as respostas não obedecem ao formato

especificado na pergunta objetiva, respondendo com o texto completo.

A acurácia nas respostas às perguntas objetivas aumentou consideravelmente com o *fine-tuning* com QLoRA, chegando a atingir 65,5% com 450 amostras. Porém, o modelo gerado com esse treinamento tende a classificar a maioria das lesões como nevo melanocítico, o que indica que a acurácia maior pode ser simplesmente devido a uma quantidade maior de nevos melanocíticos nos dados de teste. Para o modelo treinado com LoRA, o desempenho foi menor, atingindo apenas 49,5% de acurácia para a mesma quantidade de amostras.

Em geral, como pode ser visto na Subsubseção 4.2.7 e Figura 4.2.7, as duas versões foram insatisfatórias, o que se deve a um treinamento com um conjunto pequeno de dados e hiperparâmetros não ideais.




Figura 20. Matriz de confusão para o LLaMA-3.2-11B treinado com QLoRA e 450 amostras. Fonte: Autoria própria.




Figura 21. Matriz de confusão para o LLaMA-3.2-11B treinado com LoRA e 450 amostras. Fonte: Autoria própria.

A acurácia decaiu levemente após o *fine-tuning* com 900 amostras, conforme apresentado na Figura 4.2.7 e Figura 4.2.7, ficando em 65.2% para o modelo treinado com QLoRA e 42% para o treinado com LoRA. Porém, o modelo treinado com QLoRA apresenta um padrão melhor de classificação, reconhecendo melhor as lesões de nevos melanocíticos e de queratoses actínicas.




Figura 22. Matriz de confusão para o LLaMA-3.2-11B treinado com QLoRA e 900 amostras. Fonte: Autoria própria.




Figura 23. Matriz de confusão para o LLaMA-3.2-11B treinado com LoRA e 900 amostras. Fonte: Autoria própria.

Com 5000 amostras, ambos os modelos treinados com QLoRA e LoRA apresentaram resultados melhores, com 85,4% e 86,2% de acurácia, respectivamente. Deve-se observar que as configurações de treinamento foram modificadas, sendo que os dois métodos utilizaram hiperparâmetros similares. O *fine-tuning* com LoRA se mostrou levemente melhor dessa vez, demonstrando que o baixo desempenho do LoRA nos outros treinamentos foi por conta de uma escolha não ideal de hiperparâmetros. A Figura 4.2.7 e a Figura 4.2.7 apresentam estes resultados. A Figura 4.2.7 apresenta as acurácias de forma resumida.




Figura 24. Matriz de confusão do LLaMA-3.2-11B treinado com QLoRA e 5000 amostras. Fonte: Autoria própria.




Figura 25. Matriz de confusão para o LLaMA-3.2-11B treinado com LoRA e 5000 amostras. Fonte: Autoria própria.

Método de treinamento	Quantidade de amostras	Acurácia (%)
QLoRA	450	65,5
	900	65,2
	5000	85,4
LoRA	450	49,5
	900	42,0
	5000	86,2

Tabela 12. Acurácia de cada modelo treinado. Fonte: Autoria própria.

4.3. Etapa Final de Desenvolvimento

Na etapa final de desenvolvimento, o LLaMA-3.2-11B passou pelo *fine-tuning* com o conjunto de dados curados do STT/SC. O treinamento foi feito com imagens de aproximação, focando na classificação das lesões de pele e classe de risco, e também na geração de conclusões sobre as lesões com recomendações detalhadas.

4.3.1. Conjunto de Dados

O conjunto de dados curados do STT/SC possui 3651 exames e 31243 imagens. Cada exame pode possuir múltiplas séries de imagens, sendo que algumas das séries, espe-

cificamente de imagens de dermatoscopia e aproximação, estão associadas a lesões específicas. As séries de imagens panorâmicas podem incluir múltiplas lesões. Cada exame possui um texto que inclui o laudo para cada lesão de pele.

Os dados originais fornecidos incluem as imagens, um arquivo em *JavaScript Object Notation* (JSON) contendo as associações entre os identificadores (IDs) dos exames e as suas imagens, e um arquivo no formato *Comma-separated values* (CSV) com o texto dos laudos.

4.3.2. Sanitização e Preparação do Conjunto de Dados

Para realizar os experimentos, foi necessária a sanitização e preparação do conjunto de dados. A necessidade deste processo surgiu da falta de estrutura dos laudos no arquivo CSV, sendo que para cada exame, os laudos das lesões estavam unificadas em um único texto. Além disso, a formatação apresentava inconsistências e elementos indesejados, como rótulos de *HyperText Markup Language* (HTML). Por fim, o arquivo JSON possuía referências a imagens de categorias que não seriam utilizadas, como as de dermatoscopia e panorâmica. Todo o processo de sanitização foi realizado com um *Jupyter notebook* e pode ser visto na Tabela 4.3.2.

Inicialmente, foi feita extração das lesões de pele através da seleção das lesões que possuíam imagens de aproximação no arquivo JSON. Todas as lesões foram associadas aos seus respectivos exames através do ID do exame. No total, 6880 lesões de pele foram selecionadas com este processo.

Em seguida, o arquivo CSV com os laudos foi processado para substituir elementos de HTML por texto simples e estruturar as informações, separando os laudos de cada lesão. Um desafio nesta etapa foi associar corretamente as lesões aos seus respectivos laudos. Enquanto no arquivo JSON cada lesão era identificada por um número e um local no corpo, os laudos continham apenas a localização onde a lesão havia ocorrido. Essa inconsistência poderia levar a associações incorretas em casos em que mais de uma lesão tenha se manifestado na mesma parte do corpo. Para lidar com este problema, foram contabilizados somente os laudos e lesões não ambíguos. Em alguns casos, as lesões poderiam estar na mesma parte do corpo e também apresentar laudos idênticos, nessas situações as lesões e os laudos foram contabilizados.

A próxima parte do processo envolveu a associação entre as imagens e os laudos. Para cada lesão, todas as suas imagens foram associadas com uma cópia do laudo, assim, os dados passaram a ser representados por pares de imagens e laudos em uma associação de 1:1, resultando em 5988 pares. As imagens foram reescaladas para que o tamanho da maior dimensão fosse de no máximo 1024 pixels. Essa limitação no tamanho foi aplicada para contornar a falta de memória no sistema durante o treinamento.

A este ponto no processo, os dados de cada par de imagem e laudo eram os seguintes:

- ID do exame;
- Referência à imagem;
- Laudo:
 - Lesões primárias;

- Lesões secundárias;
- Colorações;
- Morfologias;
- Tamanho;
- Local;
- Distribuições;
- Classificação da lesão de pele;
- Classificação de risco;
- Conclusão;
- Conclusões sobre a lesão.

Apenas os campos de classificação da lesão de pele, classificação de risco, conclusão e conclusões sobre a lesão foram utilizados, os demais foram removidos do conjunto de dados. Ademais, os pares com lesões que possuíam menos de 15 ocorrências foram removidos, pois foram considerados como *outliers* devido à baixa representatividade. Após a filtragem, restaram 5903 pares. A estrutura de cada par no conjunto de dados filtrado é a seguinte:

- ID do exame;
- Referência à imagem;
- Laudo:
 - Classificação da lesão de pele;
 - Classificação de risco;
 - Conclusão;
 - Conclusões sobre a lesão.

As classes de lesões de pele podem se referir a uma ou mais lesões, sendo que a classe mais comum especifica que a lesão na imagem deve ser avaliada por um dermatologista presencialmente. As classificações de risco se referem à gravidade e ao encaminhamento do diagnóstico. Por fim, o campo de conclusão oferece um diagnóstico detalhado e recomendações, enquanto o campo de conclusões sobre a lesão apresenta uma descrição ou diagnóstico curto.

A distribuição de classes das lesões de pele é apresentada na Subsubseção 4.3.2. A legenda está disponível na Figura 4.3.2. A distribuição da classificação de risco também pode ser conferida na Tabela 4.3.2, com a legenda na Figura 4.3.2.




Figura 26. Distribuição das classes de lesões de pele em ordem decrescente.
Fonte: Autoria própria.

Número	Classe de lesão de pele
1	Lesões de pele que necessitam de avaliação presencial com dermatologista
2	Câncer de pele Não Melanoma (CEC ou CBC)
3	Ceratose seborreica
4	Ceratoses solares/actínicas
5	Nevo melanocítico
6	Outras
7	Fotodano crônico
8	Dermatite de Contato
9	Lesões de pele que necessitam de avaliação presencial com dermatologista pediátrico
10	Psoríase moderada a grave
11	Lesões de pele benignas com indicação de tratamento cirúrgico
12	Outras dermatoses
13	Câncer de pele Melanoma
14	Verrugas Virais
15	Tineas
16	Psoríase leve
17	Anexos/alopécias
18	Pitiríase Versicolor
19	Dermatite Atópica
20	Acne
21	Asteatose Cutânea
22	Melasma
23	Anexos/onicoses
24	Escabiose
25	Molusco Contagioso
26	Foliculite
27	Dermatite Seborreica
28	Líquen simples crônico (Neurodermite)
29	Eczema de Estase
30	Eczemas
31	Prurido
32	Rosácea
33	Colagenoses
34	Estrófulo

Tabela 13. Legenda das classes de lesões de pele. Fonte: Autoria própria.




Figura 27. Distribuição das classificações de risco em ordem decrescente.
Fonte: Autoria própria.

Rótulo	Classificação de risco
BRANCA	BRANCA - SEM NECESSIDADE DE INTERVENÇÃO OU ACOMPANHAMENTO
AZUL	AZUL - TRATAMENTO NA UNIDADE BÁSICA DE SAÚDE (UBS)
VERDE	VERDE - AVALIAÇÃO CLÍNICO-CIRURGIA COM ESPECIALISTA
AMARELA	AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO

Tabela 14. Legenda das classificações de risco. Fonte: Autoria própria.

Por fim, o conjunto de dados foi seccionado entre um conjunto de treinamento com 80% dos dados e um de testes com 20%. A divisão foi feita de forma estratificada com o método *k-fold* ($k = 5$) com o agrupamento baseado nos IDs dos exames. Este método de divisão garante que os pares de imagens e laudos de um mesmo exame fiquem no mesmo subconjunto de dados, evitando o vazamento de dados, onde o modelo é treinado com pares extremamente similares aos do conjunto de teste (GHANI et al., 2013). No total, 4736 pares foram destinados ao conjunto de dados de treinamento, enquanto 1167 pares foram para o conjunto de testes.

A criação de um terceiro conjunto de validação, como o utilizado na etapa inicial de desenvolvimento, foi considerada desnecessária. A etapa final realiza apenas uma iteração de treinamentos com hiperparâmetros pré-definidos, evitando a necessidade de validações e ajustes durante o desenvolvimento.




Figura 28. Processo de sanitização e preparação do conjunto de dados. 1: Seleção das lesões de aproximação. 2: Sanitização e estruturação dos laudos. 3: Pareamento entre imagens e laudos. 4: Filtragem e remoção de campos desnecessários dos laudos. 5: Seccionamento do conjunto de dados. Fonte: Autoria própria.

4.3.3. Estruturação dos Dados no Modelo Conversacional

Para a etapa final do desenvolvimento, o diálogo foi implementado em português, garantindo a consistência com a língua dos textos no conjunto de dados. O padrão de pergunta e resposta pode ser conferido abaixo:

Usuário: Classifique a lesão de pele na imagem, informando a classificação da lesão e classificação de risco.

Por fim, inclua uma breve conclusão sobre o diagnóstico.

As opções de classificação de lesões de pele são: **(opções de lesões de pele)**.

As opções de classificação de risco são: **(opções de classificações de risco)**.

Utilize a seguinte formatação para a resposta:

Classificação: (...).

Classificação de risco: (...).

Conclusão sobre a lesão: (...).

Conclusão: (...).

(imagem)

Modelo: Classificação: **(lesão de pele)**.

Classificação de risco: **(classificação de risco)**.

Conclusão sobre a lesão: **(conclusão sobre a lesão)**.

Conclusão: (conclusão).

O padrão de diálogo é preenchido com os dados do conjunto de treinamento e as opções de classificação de lesões de pele e de risco são oferecidas com base nas classes existentes no conjunto.

4.3.4. *Fine-tuning*

O *fine-tuning* nesta etapa é similar ao da etapa inicial, porém, como pode ser visto na Subsubseção 4.3.4, há divergências nos hiperparâmetros e na estratégia de treinamento. O tamanho do lote por dispositivo e o passo de acumulação de gradiente foram alterados para garantir que a memória do sistema seja suficiente, já que o novo conjunto de dados possui pares de imagens e texto que levam à alocação de mais memória. A taxa de aprendizado, escalonador de taxa de aprendizado e razão de aquecimento foram alterados com base em recomendações da documentação do Unsloth (2025) e do guia de *fine-tuning* de Parthasarathy et al. (2024). Por fim, o comprimento máximo da sequência de *tokens* foi limitado a 2190. Este valor foi escolhido com base na contagem do número de *tokens* em cada par do conjunto de dados, onde foi determinado que nenhum par de imagem e laudo possui mais de 2183 *tokens*.

Hiperparâmetro	Valor
Camadas e módulos treinados	Visão, linguagem, atenção e MLP
Dropout	0,1
rsLoRA	Sim
Tamanho do lote por dispositivo	4
Passo de acumulação de gradiente	1
Taxa de aprendizado	1×10^{-4}
Decaimento de peso	0,01
Escalonador da taxa de aprendizado	Linear
Razão de aquecimento	0,05
Otimizador	Adam paginado de 32 bits
Tipo numérico	BF16
Comprimento máximo da sequência	2190

Tabela 15. Hiperparâmetros para o *fine-tuning* na etapa final. A primeira seção se refere às configurações específicas de PEFT, enquanto a segunda se refere ao treinamento em geral. Fonte: Autoria própria.

Foram treinados 8 modelos com variações nos hiperparâmetros de *rank* do LoRA, α_{LoRA} e número de épocas. Essa estratégia foi utilizada para buscar hiperparâmetros próximos dos ideais para o novo conjunto de dados de treinamento. O intervalo de busca para o *rank* e α_{LoRA} constitui-se dos valores 64 e 128 para os dois hiperparâmetros, baseando-se no trabalho de Tribes et al. (2023), que indica que valores maiores levam a modelos com maior desempenho. Para o número de épocas, o intervalo utilizado foi idealizado com base nos valores recomendados pela documentação do Unsloth (2025), variando entre 2, 3, 4 e 5 épocas.

Os modelos foram treinados apenas com QLoRA inicialmente. O treinamento com LoRA foi realizado apenas uma vez, utilizando os hiperparâmetros ideais encontrados após o treinamento com QLoRA e os testes de classificação de lesões de pele. A Tabela 4.3.4 apresenta os dados dos treinamentos realizados.

<i>Rank</i> e α_{LoRA}	Número de épocas	Duração (min)	Memória (GB)
64	2	189,82	46,03
	3	284,18	46,03
	4	379,06	46,03
	5	473,66	46,03
128	2	191,17	47,57
	3	286,83	47,57
	4	381,56	47,57
	5	477,56	47,57

Tabela 16. Duração e memória utilizada durante os treinamentos com QLoRA.
Fonte: Autoria própria.

O *loss* de treinamento para cada caso pode ser conferido nas figuras a seguir:




Figura 29. Loss de treinamento para o treinamento com QLoRA, utilizando um *Rank* e α_{LoRA} de 64 e 2 épocas. Fonte: Autoria própria.




Figura 30. *Loss de treinamento para o treinamento com QLoRA, utilizando um Rank e α_{LoRA} de 64 e 3 épocas. Fonte: Autoria própria.*




Figura 31. *Loss de treinamento para o treinamento com QLoRA, utilizando um Rank e α_{LoRA} de 64 e 4 épocas. Fonte: Autoria própria.*




Figura 32. *Loss de treinamento para o treinamento com QLoRA, utilizando um Rank e α_{LoRA} de 64 e 5 épocas. Fonte: Autoria própria.*




Figura 33. *Loss de treinamento para o treinamento com QLoRA, utilizando um Rank e α_{LoRA} de 128 e 2 épocas. Fonte: Autoria própria.*




Figura 34. *Loss de treinamento para o treinamento com QLoRA, utilizando um Rank e α_{LoRA} de 128 e 3 épocas. Fonte: Autoria própria.*




Figura 35. *Loss de treinamento para o treinamento com QLoRA, utilizando um Rank e α_{LoRA} de 128 e 4 épocas. Fonte: Autoria própria.*




Figura 36. Loss de treinamento para o treinamento com QLoRA, utilizando um $Rank$ e α_{LoRA} de 128 e 5 épocas. Fonte: Autoria própria.

Após a realização dos testes, a acurácia na classificação de lesões de pele de cada modelo foi obtida. Os resultados podem ser vistos na Figura 4.3.4. O modelo treinado com o $rank$ e α_{LoRA} de 128 e com 3 épocas obteve o melhor desempenho, atingindo 45,2% de acurácia. Com base nesses hiperparâmetros, um treinamento com LoRA foi realizado, levando no total 276,46 minutos para concluir e utilizando 59,91 GB de memória. O gráfico na Tabela 4.3.4 apresenta o *loss* do treinamento com LoRA.

$Rank$ e α_{LoRA}	Número de épocas	Acurácia (%)
64	2	42,9
	3	43,9
	4	42,5
	5	43,6
128	2	44,6
	3	45,2
	4	44,0
	5	41,5

Tabela 17. Acurácia dos modelos treinados com QLoRA. Fonte: Autoria própria.




Figura 37. Loss de treinamento para o treinamento com LoRA, Rank e α_{LoRA} de 128 e 3 épocas. Fonte: Autoria própria.

4.3.5. Testes

Os testes foram realizados através da aplicação de perguntas geradas com base no diálogo da Subsubseção 4.3.3. Para os modelos que passaram pelo *fine-tuning*, foram realizados primeiramente testes com perguntas geradas a partir do conjunto de teste. O conjunto de treinamento foi utilizado posteriormente para a geração de perguntas, buscando avaliar a presença de *overfitting* ou *underfitting*. O modelo base, por sua vez, foi testado apenas com o conjunto de teste. A temperatura dos modelos foi configurada para 5×10^{-3} para garantir a objetividade nas respostas.

4.3.6. Análise do LLaMA-3.2-11B

A versão quantizada do LLaMA-3.2-11B gerou 1104 respostas válidas para as perguntas, seguindo o formato de resposta precisamente 94,6% das vezes. Enquanto a versão não quantizada gerou 1150 respostas válidas, seguindo o padrão 98,5% das vezes. Entretanto, as respostas inválidas não divergiram tanto das respostas válidas, sendo que a maioria delas estavam incorretas em pequenos detalhes de formatação. Frequentemente, essas respostas possuíam asteriscos para a formatação em *markdown* no início das seções. Um exemplo de resposta inválida pode ser visto abaixo:

Modelo: ****Classificação:**** Nevo melanocítico
****Classificação de risco:**** BRANCA - SEM NECESSIDADE DE INTERVENÇÃO OU ACOMPANHAMENTO

****Conclusão sobre a lesão:**** A lesão apresentada na imagem é caracterizada por um pequeno nódulo de cor marrom, com bordas bem definidas,

localizado na região do tronco. O tamanho da lesão é de aproximadamente 5 mm de diâmetro. A lesão não apresenta sinais de inflamação ou dor.

****Conclusão:**** A lesão apresentada na imagem é compatível com um nevo melanocítico, que é um tipo de lesão benigna da pele. O nevo melanocítico é uma lesão que se desenvolve na camada superior da pele e é causada pela multiplicação anormal de células melanocíticas. Embora seja uma lesão benigna, é importante monitorar o nevo melanocítico para garantir que não se transforme em um câncer de pele. A classificação de risco BRANCA indica que não há necessidade de intervenção ou acompanhamento imediato, mas é importante realizar um acompanhamento regular para monitorar o desenvolvimento da lesão.

Na classificação de lesões de pele, o modelo quantizado atingiu 14,8% de acurácia. A versão não quantizada ultrapassou esta métrica em 2,2%, atingindo 17% de acurácia. As matrizes de confusão na Subsubseção 4.3.6 e Figura 4.3.6 apresentam o padrão de classificação dos modelos. A maioria das predições da versão quantizada tende a classificar as lesões como “Lesões de pele que necessitam de avaliação presencial com dermatologista” ou “Ceratose seborreica”, enquanto a versão sem quantização tende a classificar a maioria apenas como “Ceratose seborreica”. Notavelmente, o modelo não quantizado classificou corretamente algumas lesões como “Câncer de pele Melanoma”.




Figura 39. Matriz de confusão da classificação das lesões de pele para o LLaMA-3.2-11B não quantizado. A classe “I” denota as respostas inválidas. A legenda das lesões está na Figura 4.3.2. Fonte: Autoria própria.

A precisão, *recall* e pontuação F1 para cada classe de lesão classificadas pelos modelos são apresentadas na Figura 4.3.6. Com estas métricas, fica evidente que o LLaMA-3.2-11B quantizado é enviesado para a previsão da primeira e terceira classe. O *recall* de 0,42 indica que 42% das ocorrências da classe 1 foram classificadas corretamente, mas a precisão de 0,15 demonstra que 85% das lesões classificadas como pertencentes à classe 1 não pertenciam de fato àquela classe. Um padrão similar entre *recall* e precisão pode ser observado na classe 3, demonstrando que o modelo base não é capaz de classificar adequadamente as lesões de pele. O comportamento do modelo não quantizado é similar, divergindo apenas nos pontos já observados na matriz de confusão.

Lesão	Modelo quantizado			Modelo não quantizado		
	Precisão	<i>Recall</i>	Pontuação F1	Precisão	<i>Recall</i>	Pontuação F1
1	0,15	0,42	0,22	0,09	0,02	0,03
2	0,50	0,10	0,17	0,33	0,27	0,30
3	0,16	0,28	0,20	0,14	0,65	0,23
4	0,11	0,05	0,07	0,00	0,00	0,00
5	0,26	0,12	0,16	0,44	0,07	0,12
6	0,00	0,00	0,00	0,00	0,00	0,00
7	0,00	0,00	0,00	0,00	0,00	0,00
8	0,00	0,00	0,00	0,00	0,00	0,00
9	0,00	0,00	0,00	0,00	0,00	0,00
10	1,00	0,08	0,15	1,00	0,08	0,15
11	0,00	0,00	0,00	0,00	0,00	0,00
12	0,00	0,00	0,00	0,00	0,00	0,00
13	0,13	0,08	0,10	0,29	0,48	0,36
14	0,00	0,00	0,00	0,00	0,00	0,00
15	0,00	0,00	0,00	0,00	0,00	0,00
16	0,00	0,00	0,00	0,00	0,00	0,00
17	0,00	0,00	0,00	0,00	0,00	0,00
18	0,00	0,00	0,00	0,00	0,00	0,00
19	0,00	0,00	0,00	0,00	0,00	0,00
20	0,00	0,00	0,00	0,50	0,08	0,13
21	0,00	0,00	0,00	0,00	0,00	0,00
22	0,00	0,00	0,00	0,00	0,00	0,00
23	0,00	0,00	0,00	0,00	0,00	0,00
24	0,00	0,00	0,00	0,00	0,00	0,00
25	0,00	0,00	0,00	0,00	0,00	0,00
26	0,00	0,00	0,00	0,00	0,00	0,00
27	0,00	0,00	0,00	0,00	0,00	0,00
28	0,00	0,00	0,00	0,00	0,00	0,00
29	0,00	0,00	0,00	0,00	0,00	0,00
30	0,00	0,00	0,00	0,00	0,00	0,00
31	0,00	0,00	0,00	0,00	0,00	0,00
32	0,00	0,00	0,00	0,00	0,00	0,00
33	0,00	0,00	0,00	0,00	0,00	0,00
34	0,00	0,00	0,00	0,00	0,00	0,00

Tabela 18. Métricas da classificação das lesões de pele com o LLaMA-3.2-11B.
Fonte: Autoria própria.

A acurácia na classificação de risco foi levemente maior, chegando a 23,4% para a versão quantizada e 27,4% para a não quantizada. Porém, de forma similar à classificação de lesões de pele, a classificação de risco foi desbalanceada e considerou a maioria das ocorrências como de categoria branca. As matrizes de confusão na Tabela 4.3.6 e Figura 4.3.6 evidenciam esta constatação para ambas as versões. A Figura 4.3.6 também reforça esta observação. 68% dos casos com risco na categoria branca foram corretamente classificados pelo modelo quantizado, mas somente 26% das classificações como categoria branca estão corretas. O padrão é similar para o modelo não quantizado.




Figura 40. Matriz de confusão da classificação de risco para o LLaMA-3.2-11B quantizado. A classe “I” denota as respostas inválidas. A legenda das classificações está na Figura 4.3.2. Fonte: Autoria própria.




Figura 41. Matriz de confusão da classificação de risco para o LLaMA-3.2-11B não quantizado. A classe “I” denota as respostas inválidas. A legenda das classificações está na Figura 4.3.2. Fonte: Autoria própria.

Risco	LLaMA quantizado			LLaMA não quantizado		
	Precisão	<i>Recall</i>	Pontuação F1	Precisão	<i>Recall</i>	Pontuação F1
BRANCA	0,26	0,68	0,38	0,26	0,75	0,39
AZUL	0,00	0,00	0,00	0,33	0,01	0,01
VERDE	0,12	0,04	0,05	0,00	0,00	0,00
AMARELA	0,42	0,13	0,20	0,39	0,26	0,31

Tabela 19. Métricas da classificação de risco com o LLaMA-3.2-11B. Fonte: Autoria própria.

Os textos das respostas geradas também foram analisados com métricas de Processamento de língua natural (PLN), especificamente, foram utilizados o *Bilingual Evaluation Understudy* (BLEU) de Papineni et al. (2002), *Recall-Oriented Understudy for Gisting Evaluation* (ROUGE) de Lin (2004) e *Metric for Evaluation of Translation with Explicit Ordering* (METEOR) de Denkowski e Lavie (2014). A Tabela 4.3.6 apresenta os valores destas métricas para as duas versões do modelo, ambos com resultados similares. O baixo valor do BLEU acumulado com diferentes n-gramas indica uma baixa precisão no uso do vocabulário e estrutura esperados. Demonstrando que uma parte considerável do texto gerado não está relacionado com o texto de referência. O *recall* medido com ROUGE é levemente maior, indicando que certas partes do texto esperado aparecem no texto gerado. Por fim, o valor da métrica METEOR, que correlaciona-se melhor com a interpretação humana, sugere que o texto gerado possui uma menor qualidade e está distante do esperado.

Métrica	Valor (Modelo quantizado)	Valor (Modelo não quantizado)
BLEU-1	0,181	0,192
BLEU-2	0,125	0,129
BLEU-3	0,099	0,102
BLEU-4	0,081	0,083
ROUGE-1 (<i>recall</i>)	0,422	0,417
ROUGE-L (<i>recall</i>)	0,330	0,313
METEOR	0,211	0,221

Tabela 20. Métricas de PLN do texto das respostas geradas pelo LLaMA-3.2-11B. Fonte: Autoria própria.

4.3.7. Análise do Modelo Treinado com QLoRA

O modelo treinado com QLoRA respondeu a todas as perguntas de forma válida e atingiu uma acurácia de 45,2% na classificação de lesões de pele com as perguntas do conjunto de teste, ultrapassando o modelo base não quantizado em 28,2%. A Subsubseção 4.3.7 apresenta a matriz de confusão da classificação das lesões de pele. Observa-se que o modelo capturou razoavelmente o padrão de classificação, mas seu desempenho geral foi pouco satisfatório.

Este modelo gerou 4735 respostas válidas sobre os dados de treinamento, falhando em seguir as instruções em apenas resposta. Esta resposta se tratava da classificação

de uma lesão como “Hemangioma”, uma classe que não estava presente no domínio de lesões. Entretanto, ela era mencionada na seção de conclusões sobre a lesão nos dados de treinamento. A acurácia na classificação das lesões sobre os dados de treinamento foi de 55,1%. A matriz de confusão referente aos testes sobre o conjunto de treinamento pode ser conferida na Figura 4.3.7.




Figura 42. Matriz de confusão da classificação das lesões de pele sobre o conjunto de teste para o LLaMA-3.2-11B treinado com QLoRA. A legenda das lesões está na Figura 4.3.2. Fonte: Autoria própria.




Figura 43. Matriz de confusão da classificação das lesões de pele sobre o conjunto de treinamento para o LLaMA-3.2-11B treinado com QLoRA. A classe “1” denota as respostas inválidas. A legenda das lesões está na Figura 4.3.2. Fonte: Autoria própria.

A Figura 4.3.7 apresenta as métricas de classificação para as classes. O melhor desempenho de classificação foi atingido com a classe 2, correspondente ao câncer de pele não melanoma, onde a pontuação F1 foi de 0,61. O desempenho para a maioria das classes ficou abaixo do esperado, principalmente para as lesões mais raras. O baixo desempenho nos testes sobre o conjunto de treinamento indicam também que o modelo não aprendeu efetivamente os padrões de classificação, caracterizando um possível *underfitting*.

Lesão	Conjunto de testes			Conjunto de treinamento		
	Precisão	<i>Recall</i>	Pontuação F1	Precisão	<i>Recall</i>	Pontuação F1
1	0,46	0,47	0,46	0,59	0,53	0,56
2	0,55	0,68	0,61	0,68	0,78	0,73
3	0,57	0,63	0,60	0,52	0,70	0,60
4	0,38	0,46	0,42	0,47	0,61	0,53
5	0,32	0,60	0,41	0,48	0,67	0,56
6	0,23	0,23	0,23	0,35	0,29	0,32
7	0,39	0,19	0,25	0,46	0,18	0,26
8	0,45	0,16	0,24	0,64	0,36	0,46
9	0,69	0,46	0,55	0,63	0,57	0,60
10	0,44	0,80	0,57	0,45	0,72	0,55
11	0,00	0,00	0,00	0,62	0,08	0,14
12	0,00	0,00	0,00	1,00	0,02	0,04
13	1,00	0,12	0,21	0,82	0,42	0,55
14	0,27	0,25	0,26	0,64	0,48	0,55
15	0,00	0,00	0,00	0,76	0,26	0,39
16	0,00	0,00	0,00	0,00	0,00	0,00
17	0,08	1,00	0,14	0,67	0,60	0,63
18	0,00	0,00	0,00	0,53	0,37	0,44
19	0,00	0,00	0,00	0,20	0,03	0,04
20	0,57	0,31	0,40	0,47	0,42	0,44
21	0,00	0,00	0,00	0,52	0,48	0,50
22	0,20	0,29	0,24	0,68	0,74	0,71
23	0,25	0,60	0,35	0,44	0,74	0,56
24	0,00	0,00	0,00	0,00	0,00	0,00
25	0,50	0,25	0,33	0,82	0,61	0,70
26	0,00	0,00	0,00	0,00	0,00	0,00
27	0,33	0,10	0,15	0,22	0,11	0,15
28	0,67	0,25	0,36	0,33	0,31	0,32
29	0,00	0,00	0,00	0,27	0,18	0,21
30	0,00	0,00	0,00	0,27	0,21	0,24
31	0,00	0,00	0,00	0,00	0,00	0,00
32	0,00	0,00	0,00	1,00	0,08	0,15
33	0,00	0,00	0,00	0,00	0,00	0,00
34	0,00	0,00	0,00	0,75	0,23	0,35

Tabela 21. Métricas da classificação das lesões de pele sobre os conjuntos de teste e treinamento com o LLaMA-3.2-11B treinado com QLoRA. Fonte: Autoria própria.

A acurácia da classificação de risco foi de 54,6%, 27,4% maior do que a acurácia obtida pelo modelo base não quantizado. O testes sobre o conjunto de treinamento apresentaram uma acurácia de 64,3%. Assim como na classificação de lesões, o desempenho nesta tarefa foi considerado insatisfatório, porém, um pouco melhor. A Tabela 4.3.7 e Figura 4.3.7 apresentam as matrizes de confusão, onde observa-se que o modelo treinado com QLoRA foi capaz de capturar o padrão de classificação de risco razoavelmente. Na Figura 4.3.7, pode-se ver que o desempenho na classificação é similar entre as classes, sendo levemente maior para as classes mais frequentes.




Figura 44. Matriz de confusão da classificação de risco sobre o conjunto de teste para o LLaMA-3.2-11B treinado com QLoRA. A legenda das classificações está na Figura 4.3.2. Fonte: Autoria própria.




Figura 45. Matriz de confusão da classificação de risco sobre o conjunto de treinamento para o LLaMA-3.2-11B treinado com QLoRA. A classe “I” denota as respostas inválidas. A legenda das classificações está na Figura 4.3.2. Fonte: Autoria própria.

Risco	Conjunto de testes			Conjunto de treinamento		
	Precisão	<i>Recall</i>	Pontuação F1	Precisão	<i>Recall</i>	Pontuação F1
BRANCA	0,63	0,72	0,67	0,68	0,77	0,72
AZUL	0,48	0,37	0,42	0,59	0,50	0,54
VERDE	0,51	0,46	0,48	0,63	0,55	0,59
AMARELA	0,52	0,63	0,57	0,66	0,75	0,70

Tabela 22. Métricas da classificação de risco sobre os conjuntos de teste e treinamento com o LLaMA-3.2-11B treinado com QLoRA. Fonte: Autoria própria.

As métricas de PLN apresentadas na Tabela 4.3.7 demonstram que o LLaMA-3.2-11B treinado com QLoRA atingiu um desempenho suficientemente adequado na geração de textos de conclusão sobre as lesões. O BLEU-1 acumulado indica que 55,1% das palavras no texto gerado estão presentes também no texto do conjunto de teste, indicando que o modelo utiliza o vocabulário esperado. O restante dos valores de BLEU com múltiplos n-gramas constata a capacidade do modelo de gerar texto com uma precisão aceitável. O ROUGE-1 também demonstra que 67,8% das palavras do texto do conjunto de teste aparecem no texto gerado, além disso, o ROUGE-L confirma que a estrutura do texto de referência é seguida no texto gerado de forma aceitável. Por fim, o valor de METEOR indica uma qualidade geral adequada.

Métrica	Valor (conjunto de teste)	Valor (conjunto de treinamento)
BLEU-1	0,551	0,640
BLEU-2	0,524	0,616
BLEU-3	0,511	0,605
BLEU-4	0,500	0,595
ROUGE-1 (<i>recall</i>)	0,678	0,742
ROUGE-L (<i>recall</i>)	0,629	0,704
METEOR	0,580	0,663

Tabela 23. Métricas de PLN do texto das respostas geradas sobre os conjuntos de teste e treinamento pelo modelo treinado com QLoRA. Fonte: Autoria própria.

4.3.8. Análise do Modelo Treinado com LoRA

O LLaMA-3.2-11B treinado com LoRA seguiu com resultados similares ao do modelo treinado com QLoRA. Nos testes realizados sobre o conjunto de teste, a maioria das respostas foi válida, com a exceção de apenas uma. A resposta inválida classificou uma lesão como “Nevo intradérmico”, sendo que esta lesão não está no domínio de classificação. Para os testes sobre o conjunto de treinamento, apenas uma resposta inválida foi gerada. Esta resposta classificou a lesão da pergunta como “Verruga Viral”, que embora seja similar à lesão válida “Verrugas Virais”, não é considerada válida nesta análise.

A acurácia na classificação de lesões de pele com o conjunto de testes foi de 44,5%, 0,7% menor do que a atingida pelo modelo treinado com QLoRA. Com os testes sobre o conjunto de treinamento, a acurácia foi de 59%, ultrapassando o modelo treinado com QLoRA em 3,9%. As matrizes de confusão na Subsubseção 4.3.8 e Figura 4.3.8

apresentam padrões de classificação extremamente similares aos padrões do modelo treinado com QLoRA.




Figura 46. Matriz de confusão da classificação das lesões de pele sobre o conjunto de teste para o LLaMA-3.2-11B treinado com LoRA. A classe “I” denota as respostas inválidas. A legenda das lesões está na Figura 4.3.2. Fonte: Autoria própria.




Figura 47. Matriz de confusão da classificação das lesões de pele sobre o conjunto de treinamento para o LLaMA-3.2-11B treinado com LoRA. A classe “I” denota as respostas inválidas. A legenda das lesões está na Figura 4.3.2. Fonte: Autoria própria.

As métricas de classificação apresentadas na Figura 4.3.8 não demonstram grandes divergências entre os modelos treinados com as duas técnicas. As médias da pontuação F1 para as classificações sobre o conjunto de teste e de treinamento são 42,5% e 57,6%, respectivamente. Assim como na análise da classificação das lesões da seção anterior, este baixo desempenho em ambos os casos sugere *underfitting*.

Lesão	Conjunto de testes			Conjunto de treinamento		
	Precisão	<i>Recall</i>	Pontuação F1	Precisão	<i>Recall</i>	Pontuação F1
1	0,42	0,48	0,45	0,61	0,60	0,61
2	0,57	0,66	0,61	0,72	0,79	0,75
3	0,58	0,56	0,57	0,56	0,70	0,62
4	0,38	0,45	0,41	0,50	0,63	0,56
5	0,35	0,67	0,46	0,51	0,68	0,58
6	0,11	0,05	0,06	0,46	0,30	0,36
7	0,30	0,29	0,30	0,43	0,33	0,38
8	0,35	0,23	0,27	0,65	0,45	0,53
9	0,60	0,54	0,57	0,73	0,71	0,72
10	0,64	0,64	0,64	0,62	0,65	0,63
11	0,50	0,16	0,24	0,65	0,21	0,32
12	0,00	0,00	0,00	0,00	0,00	0,00
13	0,67	0,16	0,26	0,79	0,44	0,57
14	0,25	0,12	0,17	0,67	0,57	0,62
15	0,00	0,00	0,00	0,75	0,30	0,43
16	0,00	0,00	0,00	0,50	0,24	0,32
17	0,11	1,00	0,20	0,72	0,60	0,65
18	0,20	0,33	0,25	0,46	0,61	0,52
19	0,20	0,11	0,14	0,29	0,28	0,28
20	0,60	0,23	0,33	0,62	0,48	0,54
21	0,00	0,00	0,00	0,48	0,48	0,48
22	0,29	0,57	0,38	0,78	0,68	0,72
23	0,33	0,60	0,43	0,57	0,74	0,65
24	0,00	0,00	0,00	1,00	0,05	0,09
25	1,00	0,38	0,55	0,75	0,52	0,62
26	0,00	0,00	0,00	1,00	0,07	0,13
27	0,67	0,20	0,31	0,25	0,11	0,15
28	0,00	0,00	0,00	0,57	0,25	0,35
29	0,00	0,00	0,00	0,50	0,47	0,48
30	0,00	0,00	0,00	0,37	0,37	0,37
31	0,00	0,00	0,00	0,00	0,00	0,00
32	0,00	0,00	0,00	0,00	0,00	0,00
33	0,00	0,00	0,00	1,00	0,27	0,43
34	0,00	0,00	0,00	0,71	0,38	0,50

Tabela 24. Métricas da classificação das lesões de pele sobre os conjuntos de teste e treinamento com o LLaMA-3.2-11B treinado com LoRA. Fonte: Autoria própria.

A acurácia na classificação de risco com as perguntas do conjunto de teste foi de 55,1%, superando o modelo treinado com QLoRA em apenas 0,5%. Sobre as perguntas do conjunto de treinamento, a acurácia foi de 66,7%, ultrapassando o LLaMA-3.2-11B treinado com QLoRA em 2,4%. As matrizes de confusão podem ser conferidas na Tabela 4.3.8 e Figura 4.3.8. Além disso, os dados da Figura 4.3.8 demonstram que o modelo treinado com LoRA possui um desempenho levemente maior na classificação de categorias de risco, porém, as métricas ainda são similares.




Figura 48. Matriz de confusão da classificação de risco sobre o conjunto de teste para o LLaMA-3.2-11B treinado com LoRA. A classe “I” denota as respostas inválidas. A legenda das classificações está na Figura 4.3.2. Fonte: Autoria própria.




Figura 49. Matriz de confusão da classificação de risco sobre o conjunto de treinamento para o LLaMA-3.2-11B treinado com LoRA. A classe “I” denota as respostas inválidas. A legenda das classificações está na Figura 4.3.2. Fonte: Autoria própria.

Risco	Conjunto de testes			Conjunto de treinamento		
	Precisão	<i>Recall</i>	Pontuação F1	Precisão	<i>Recall</i>	Pontuação F1
BRANCA	0,66	0,70	0,68	0,71	0,78	0,74
AZUL	0,49	0,40	0,44	0,61	0,55	0,58
VERDE	0,47	0,54	0,50	0,61	0,63	0,62
AMARELA	0,56	0,55	0,55	0,73	0,70	0,71

Tabela 25. Métricas da classificação de risco sobre os conjuntos de teste e treinamento com o LLaMA-3.2-11B treinado com LoRA. Fonte: Autoria própria.

O desempenho nas métricas de PLN do modelo treinado com LoRA demonstram que este modelo é levemente pior na geração de texto do que a versão treinada com QLoRA.

Métrica	Valor (conjunto de teste)	Valor (conjunto de treinamento)
BLEU-1	0,545	0,660
BLEU-2	0,517	0,639
BLEU-3	0,504	0,628
BLEU-4	0,493	0,619
ROUGE-1 (<i>recall</i>)	0,677	0,760
ROUGE-L (<i>recall</i>)	0,627	0,724
METEOR	0,576	0,684

Tabela 26. Métricas de PLN do texto das respostas geradas sobre os conjuntos de teste e treinamento pelo modelo treinado com LoRA. Fonte: Autoria própria.

5. Análise Comparativa

Nesta seção será realizada uma análise comparativa dos modelos resultantes do *fine-tuning* realizado nas duas etapas de desenvolvimento. Além disso serão feitas comparações com o modelo base e entre os métodos de treinamento.

5.1. Desempenho na Classificação de Lesões de Pele

Os resultados obtidos na etapa final de desenvolvimento indicam que os modelos que passaram pelo *fine-tuning* para a classificação de lesões de pele com imagens de aproximação obtiveram um desempenho mediano, ficando abaixo do esperado. Em comparação com os modelos da primeira etapa, treinados para a classificação com imagens de dermatoscopia, a acurácia foi consideravelmente menor.

Os modelos da primeira etapa obtiveram um desempenho superior com um quantidade muito menor de dados, comparativamente, o modelo treinado com QLoRA e 5000 imagens de dermatoscopia superou o modelo treinado com QLoRA e 4736 imagens de aproximação em 42,2%. Embora existam diferenças nos hiperparâmetros de treinamento desses modelos, a divergência é significativa demais para estar relacionada apenas com os hiperparâmetros.

A Subseção 5.1 apresenta uma comparação entre todos os testes realizados. Os modelos que passaram pelo *fine-tuning* apresentaram um desempenho substancialmente superior ao do modelo base na classificação das lesões.

Tipo de imagem	Método de <i>fine-tuning</i>	Volume de treinamento	Acurácia (%)
Dermatoscopia	Nenhum (Quantizado)	-	11,8
	Nenhum	-	14,0
	QLoRA	450	65,5
		900	65,2
		5000	85,4
	LoRA	450	49,5
		900	42,0
		5000	86,2
Aproximação	Nenhum (Quantizado)	-	14,8
	Nenhum	-	17,0
	QLoRA	4736	45,2
	LoRA	4736	44,5

Tabela 27. Acurácia na classificação de lesões de pele nos testes realizados neste trabalho. Os valores em negrito indicam as maiores acurácias para o tipo de imagem especificado. Fonte: Autoria própria.

5.2. Desempenho na Classificação de Risco

A classificação de risco introduzida na etapa final do trabalho apresentou um cenário mais promissor no desempenho, porém a acurácia ainda foi mediana e pouco satisfatória. A Subseção 5.2 apresenta uma visão comparativa da acurácia na classificação das categorias de risco, evidenciando as melhorias no desempenho proporcionadas pelo *fine-tuning*.

Método de <i>fine-tuning</i>	Acurácia (%)
Nenhum (Quantizado)	23,4
Nenhum	27,4
QLoRA	54,6
LoRA	55,1

Tabela 28. Acurácia na classificação de risco para os testes da etapa final de desenvolvimento. O valor em negrito indica a maior acurácia. Fonte: Autoria própria.

5.3. Desempenho na Geração de Laudos

O desempenho na geração de texto foi considerado satisfatório, conforme pode ser visto na Subseção 5.3, tanto o modelo treinado com o QLoRA quanto o com LoRA atingiram um desempenho superior ao do modelo base, constatando que os modelos conseguiram generalizar o formato de geração do texto do laudo.

Métrica	Método de <i>fine-tuning</i>			
	Nenhum (Quantizado)	Nenhum	QLoRA	LoRA
BLEU-1	0,181	0,192	0,551	0,545
BLEU-2	0,125	0,129	0,524	0,517
BLEU-3	0,099	0,102	0,511	0,504
BLEU-4	0,081	0,083	0,500	0,493
ROUGE-1 (<i>recall</i>)	0,422	0,417	0,678	0,677
ROUGE-L (<i>recall</i>)	0,330	0,313	0,629	0,627
METEOR	0,211	0,221	0,580	0,576

Tabela 29. Métricas de PLN do texto das respostas geradas sobre os testes na etapa final de desenvolvimento. Os maiores valores de cada métrica estão destacados em negrito. Fonte: Autoria própria.

A fim de realizar uma análise aprofundada da geração de texto, as respostas abaixo foram coletadas dos resultados dos testes. Primeiramente, o texto de referência é apresentado:

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).
Classificação de risco: AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO.
Conclusão sobre a lesão: compatível com câncer da pele.
Conclusão: Encaminhar o paciente para o ambulatório de Dermatologia - CÂNCER DA PELE/Cirurgia Dermatológica ou referência regional.

Se o paciente já realizou biópsia da lesão, o resultado deve ser levado no dia da cirurgia.

As duas respostas abaixo foram geradas pelo LLaMA-3.2-11B quantizado e não quantizado, respectivamente. Os modelos classificaram corretamente a lesão de pele, mas apenas a versão quantizada categorizou o risco de forma correta. Além disso, as conclusões não apresentaram as recomendações ideais.

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).
Classificação de risco: AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO.
Conclusão sobre a lesão: A lesão apresentada na imagem é caracterizada por uma lesão de pele com aspecto ulcerado e com bordas irregulares, o que sugere uma lesão maligna. A classificação de risco como amarela indica que a lesão requer acompanhamento e tratamento em um ambulatório de referência terciário.
Conclusão: A lesão apresentada na imagem é suspeita de câncer de pele não melanoma e requer acompanhamento e tratamento em um ambulatório de referência terciário.

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).
Classificação de risco: BRANCA - SEM NECESSIDADE DE INTERVENÇÃO OU ACOMPANHAMENTO.

Conclusão sobre a lesão: A lesão apresentada na imagem é caracterizada por uma lesão de pele com uma borda irregular e um centro escuro, o que sugere uma lesão maligna. A presença de uma lesão de pele com essas características é compatível com um Câncer de pele Não Melanoma (CEC ou CBC).

Conclusão: A lesão apresentada na imagem é compatível com um Câncer de pele Não Melanoma (CEC ou CBC) e deve ser avaliada por um especialista em dermatologia.

As respostas seguintes foram geradas com o LLaMA-3.2-11B treinado com QLoRA e LoRA, respectivamente. Ambos classificaram as lesões e as categorias de risco corretamente. As conclusões geradas seguem o texto de referência com precisão, mas apresentam a palavra “compatível” com a grafia incorreta, omitindo o acento agudo. O texto gerado também inclui um espaçamento inesperado.

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).
Classificação de risco: AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO.

Conclusão sobre a lesão: compatível com câncer da pele.

Conclusão: Encaminhar o paciente para o ambulatório de Dermatologia - Câncer da Pele/Cirurgia Dermatológica ou referência regional.

Se o paciente já realizou biópsia da lesão, o resultado deve ser levado no dia da cirurgia.

Modelo: Classificação: Câncer de pele Não Melanoma (CEC ou CBC).
Classificação de risco: AMARELA - ENCAMINHAMENTO COM PRIORIDADE PARA O AMBULATÓRIO DE REFERÊNCIA TERCIÁRIO.

Conclusão sobre a lesão: compatível com câncer da pele.

Conclusão: Encaminhar o paciente para o ambulatório de Dermatologia - Câncer da Pele/Cirurgia Dermatológica ou referência regional.

Se o paciente já realizou biópsia da lesão, o resultado deve ser levado no dia da cirurgia.

5.4. Comparação entre as Técnicas de Treinamento

Por fim, comparando as métricas de treinamento apresentadas na Subseção 5.4, Figura 5.4 e Figura 5.4, observa-se que ambos os métodos de treinamento tomam uma quantidade

similar de tempo para serem concluídos. O tempo de treinamento também tende a escalar na mesma taxa para ambos os métodos, mesmo com diferentes volumes de dados. Ademais, o método LoRA tende a utilizar uma quantidade maior de memória, com um uso médio de 84,19% a mais de memória em relação ao QLoRA na etapa inicial. Na etapa final, o LoRA utilizou 25,94% a mais de memória. A disparidade entre essas diferenças para as duas etapas pode ser explicada pelas alterações nos hiperparâmetros que afetam o uso da memória, como tamanho do lote por dispositivo e o passo de acumulação de gradiente. Além disso, é possível que as características dos conjunto de dados tenham influenciado nesta diferença.




Figura 50. Tempo de treinamento dos modelos da etapa inicial com diferentes técnicas de treinamento. Fonte: Autoria própria.




Figura 51. Memória utilizada no treinamento dos modelos da etapa inicial com diferentes técnicas de treinamento. Fonte: Autoria própria.

Método de treinamento	Tempo de treinamento (min)	Memória utilizada (GB)
QLoRA	286,83	47,57
LoRA	276,46	59,91

Tabela 30. Métricas de treinamento para a etapa final do projeto. Fonte: Autoria própria.

6. Conclusão

Neste trabalho, foi realizado o *fine-tuning* do MLLM LLaMA-3.2-11B com as técnicas de treinamento QLoRA e LoRA. Os modelos provenientes do *fine-tuning* nas duas etapas de desenvolvimento foram analisados e comparados com o modelo base e também entre si, oferecendo informações relevantes sobre o impacto dos diferentes métodos de treinamento.

Os resultados apresentados constatarem que o *fine-tuning* do modelo LLaMA-3.2-11B pode ser feito de forma eficiente através do treinamento com QLoRA. Os modelos treinados com este método obtiveram um desempenho semelhante ao dos modelos treinados com LoRA e requisitaram menos memória durante o treinamento.

Na etapa inicial, os resultados obtidos foram satisfatórios e demonstraram que através do *fine-tuning* com QLoRA com 5000 amostras do conjunto de dados é possível atingir uma acurácia na classificação de lesões de pele de 85,4%, o que é próximo da acurácia de 86,2% obtida com o LoRA para o mesmo volume de dados. Porém, os resultados da etapa final foram poucos satisfatórios quanto ao critério de classificação de lesões, atingindo apenas 45,2% de acurácia após o treinamento com QLoRA. Embora o volume de dados utilizado nesta etapa tenha sido similar, com um total de 4736 pares de

imagem e texto de resposta, o conteúdo em si das imagens e do texto eram consideravelmente diferentes. As imagens de aproximação utilizadas possuem uma complexidade visual muito maior, pois elas incluem elementos extras além da lesão de pele, como o resto do ambiente ao redor do local da lesão. Além disso, os textos utilizados possuem não só uma seção para a classificação da lesão, mas também uma seção para a classificação de risco, conclusão sobre a lesão e conclusão geral.

O volume de dados no conjunto de treinamento pode ter sido insuficiente para o *fine-tuning*, impossibilitando os modelos finais de realizarem uma tarefa complexa como a geração de laudos com classificações e recomendações. Além do volume insuficiente, o desbalanceamento do conjunto de dados, caracterizado pela raridade de algumas lesões, pode ter impactado os modelos treinados, levando a um desempenho inferior na classificação de lesões com poucas ocorrências no conjunto de dados. Outro aspecto negativo do conjunto foi a variabilidade dentro de algumas classes de lesões. As classes “Lesões de pele que necessitam de avaliação presencial com dermatologista”, “Lesões de pele que necessitam de avaliação presencial com dermatologista pediátrico” e “Outras” compõem 27,11% do conjunto de dados de treinamento e incluem diversas lesões não relacionadas. Este grande volume de classes incertas pode ter levado ao baixo desempenho observado nas tarefas de classificação.

O desempenho na geração dos textos de conclusão na etapa final foi razoavelmente satisfatório, porém, alguns problemas foram identificados, como erros ortográficos e formatações não ideais. Essas características também são provenientes de inconsistências e erros no conjunto de dados.

Por fim, os resultados dos testes na segunda etapa sobre o conjunto de treinamento evidenciaram que o LLaMA-3.2-11B após o *fine-tuning* não foi capaz de capturar o padrão de classificação de lesões de pele, o que indica que para este tipo de tarefa, um conjunto de dados limpo e bem estruturado é necessário.

Em geral, considera-se necessária a adaptação e expansão do conjunto de dados para que o desenvolvimento de um novo modelo com um maior desempenho seja possível.

6.1. Trabalhos Futuros

Considerando os resultados e limitações constatadas neste projeto, propõe-se a construção de um novo conjunto de dados com um maior volume e consistência entre as classes. Seria necessário incluir também uma nova classe referente a casos saudáveis, pois atualmente o modelo passa pelo *fine-tuning* para classificar somente diferentes lesões de pele, desconsiderando a possibilidade da ausência de lesões.

Recomenda-se também a otimização aprofundada dos hiperparâmetros de treinamento, possivelmente com técnicas de busca em grade e ferramentas como W&B Sweeps e Optuna (SHUKLA, 2024; AKIBA et al., 2019).

A utilização de outros MLLMs também é recomendada, particularmente a do Gemma 3 de Kamath et al. (2025). Isso tornaria possível a realização de uma comparação mais avançada entre os diferentes modelos.

Por fim, sugere-se a utilização de avaliações manuais sobre partes dos resultados dos testes. Atualmente, os resultados são analisados de forma automática, o que pode levar à desconsideração de aspectos importantes do texto gerado. Com a participação

de dermatologistas qualificados, seria possível avaliar o conteúdo destes textos de forma mais aprofundada.

Referências

- AKIBA, Takuya et al. Optuna: A Next-generation Hyperparameter Optimization Framework. In: PROCEEDINGS of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. [S.l.: s.n.], 2019.
- BONO, Aldo et al. Melanoma Detection: A Prospective Study Comparing Diagnosis with the Naked Eye, Dermatoscopy and Telespectrophotometry. **Dermatology**, v. 205, n. 4, p. 362–366, dez. 2002. ISSN 1018-8665. DOI: 10.1159/000066436. eprint: <https://karger.com/drm/article-pdf/205/4/362/2647462/000066436.pdf>. Disponível em: <https://doi.org/10.1159/000066436>.
- CAO, Xu et al. MpoxVLM: A Vision-Language Model for Diagnosing Skin Lesions from Mpox Virus Infection. **arXiv preprint arXiv:2411.10888**, 2024.
- CHENG, Junlong et al. Sam-med2d. **arXiv preprint arXiv:2308.16184**, 2023.
- DENKOWSKI, Michael; LAVIE, Alon. Meteor universal: Language specific translation evaluation for any target language. In: PROCEEDINGS of the ninth workshop on statistical machine translation. [S.l.: s.n.], 2014. p. 376–380.
- DETTMERS, Tim et al. Qlora: Efficient finetuning of quantized llms. **Advances in Neural Information Processing Systems**, v. 36, 2024.
- DOSOVITSKIY, Alexey. An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv preprint arXiv:2010.11929**, 2020.
- DUBEY, Abhimanyu et al. The llama 3 herd of models. **arXiv preprint arXiv:2407.21783**, 2024.
- EVARISTO, Eric Fernandes et al. Systematic Literature Review on Multimodal Large Language Models applied to Medical Image Data. **Relatórios Técnicos do INCoD - ISSN 2236-5281**, v. 15, mai. 2025. DOI: 10.13140/RG.2.2.32280.10244.
- FILGUEIRAS, Andréa Sabino; SILVA, Ana Lúcia Abrahão. Agente Comunitário de Saúde: um novo ator no cenário da saúde do Brasil. **Physis: Revista de Saúde Coletiva**, SciELO Public Health, v. 21, p. 899–916, 2011.
- GHANI, Rayid et al. **Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining**. [S.l.]: ACM, 2013. p. 556–563.
- HABIF, Thomas P. **Clinical dermatology E-book**. [S.l.]: Elsevier Health Sciences, 2015. p. 1–19.

HU, Edward J et al. Lora: Low-rank adaptation of large language models. **arXiv preprint arXiv:2106.09685**, 2021.

HU, Yutao et al. Omnimedvqa: A new large-scale comprehensive evaluation benchmark for medical lvlm. In: PROCEEDINGS of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2024. p. 22170–22183.

HUANG, Xiaoshuang et al. Towards a multimodal large language model with pixel-level insight for biomedicine. In: 4. PROCEEDINGS of the AAAI Conference on Artificial Intelligence. [S.l.: s.n.], 2024. v. 39, p. 3779–3787.

JABLONSKI, Nina G. The evolution of human skin and skin color. **Annu. Rev. Anthropol.**, Annual Reviews, v. 33, n. 1, p. 585–623, 2004.

KALAJDZIEVSKI, Damjan. A rank stabilization scaling factor for fine-tuning with lora. **arXiv preprint arXiv:2312.03732**, 2023.

KAMATH, Aishwarya et al. Gemma 3 technical report. **arXiv preprint arXiv:2503.19786**, 2025.

LIMA VAZQUEZ, Vinicius de et al. Melanoma characteristics in Brazil: demographics, treatment, and survival analysis. **BMC Research Notes**, 2015. DOI: 10.1186/s13104-015-0972-8.

LIN, Chin-Yew. Rouge: A package for automatic evaluation of summaries. In: TEXT summarization branches out. [S.l.: s.n.], 2004. p. 74–81.

LOW, Daniel. **Skin Cancer**. [S.l.: s.n.], 2023. Disponível em: https://huggingface.co/datasets/marmal88/skin_cancer. Acesso em: 8 dez. 2024.

MAUAD, Edmundo C et al. Opportunistic screening for skin cancer using a mobile unit in Brazil. **BMC Dermatology**, 2011. DOI: 10.1186/1471-5945-11-12.

MINAEE, Shervin et al. Large language models: A survey. **arXiv preprint arXiv:2402.06196**, 2024.

MINISTÉRIO DA SAÚDE. **Câncer de pele**. [S.l.: s.n.], 2020. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/c/cancer-de-pele>. Acesso em: 23 jun. 2024.

PANAGOULIAS, Dimitrios P.; VIRVOU, Maria; TSIHRINTZIS, George A. Evaluating LLM – Generated Multimodal Diagnosis from Medical Images and Symptom Analysis, 2024. DOI: 10.48550/arXiv.2402.01730.

PAPINENI, Kishore et al. Bleu: a method for automatic evaluation of machine translation. In: PROCEEDINGS of the 40th annual meeting of the Association for Computational Linguistics. [S.l.: s.n.], 2002. p. 311–318.

PARTHASARATHY, Venkatesh Balavadhani et al. The ultimate guide to fine-tuning llms from basics to breakthroughs: An exhaustive review of technologies, research, best practices, applied research challenges and opportunities. **arXiv preprint arXiv:2408.13296**, 2024.

PEFT. **PEFT**. [S.l.: s.n.], 2021. Disponível em: <https://huggingface.co/docs/peft>. Acesso em: 23 jun. 2024.

RADFORD, Alec et al. Learning transferable visual models from natural language supervision. In: PMLR. INTERNATIONAL conference on machine learning. [S.l.: s.n.], 2021. p. 8748–8763.

SANTOS, José Alcides Figueiredo. Desigualdades e interações de classe social na saúde no Brasil. **Dados**, SciELO Brasil, v. 63, n. 1, e20180104, 2020.

SHUKLA, Lavanya. **Introduction to Hyperparameter Sweeps - A Model Battle Royale To Find The Best Model In 3 Steps**. [S.l.: s.n.], 2024. Disponível em: https://wandb.ai/wandb_fc/articles/reports/Introduction-to-Hyperparameter-Sweeps-A-Model-Battle-Royale-To-Find-The-Best-Model-In-3-Steps--Vmlldzo1NDQ2Nzk5. Acesso em: 11 dez. 2024.

SUMITHRA, Ra; SUHIL, Mahamad; GURU, DS. Segmentation and classification of skin lesions for disease diagnosis. **Procedia Computer Science**, Elsevier, v. 45, p. 76–85, 2015.

TOUVRON, Hugo et al. Llama: Open and efficient foundation language models. **arXiv preprint arXiv:2302.13971**, 2023.

TRIBES, Christophe et al. Hyperparameter optimization for large language model instruction-tuning. **arXiv preprint arXiv:2312.00949**, 2023.

TSCHANDL, Philipp; ROSENDAHL, Cliff; KITTLER, Harald. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. **Scientific data**, Nature Publishing Group, v. 5, n. 1, p. 1–9, 2018.

UNSLOTH. **LoRA Hyperparameters Guide**. [S.l.: s.n.], 2025. Disponível em: <https://docs.unsloth.ai/get-started/fine-tuning-guide/lora-hyperparameters-guide>. Acesso em: 8 jun. 2025.

VASWANI, Ashish et al. Attention is all you need. **Advances in neural information processing systems**, v. 30, 2017.

VON WANGENHEIM, Aldo; WAGNER, Harley; NOGUEIRA, João. Telemedicina STT/SC - Manual de Registro Fotográfico de Dermatologia Detalhado. **Relatórios Técnicos do INCoD - ISSN 2236-5281**, v. 3, p. 1–5, dez. 2013. DOI: 10.13140/2.1.5022.5922.

WANG, Peng et al. Qwen2-vl: Enhancing vision-language model's perception of the world at any resolution. **arXiv preprint arXiv:2409.12191**, 2024.

YANG, Jiancheng; SHI, Rui; NI, Bingbing. Medmnist classification decathlon: A lightweight automl benchmark for medical image analysis. In: IEEE. 2021 IEEE 18th International Symposium on Biomedical Imaging (ISBI). [S.l.: s.n.], 2021. p. 191–195.

YIN, Shukang et al. A survey on multimodal large language models. **arXiv preprint arXiv:2306.13549**, 2023.

YOUL, Philippa H. et al. Association between melanoma thickness, clinical skin examination and socioeconomic status: Results of a large population-based study. **International Journal of Cancer**, v. 128, n. 9, p. 2158–2165, 2011. DOI: <https://doi.org/10.1002/ijc.25540>.

YU, Haiyang et al. UMIT: Unifying Medical Imaging Tasks via Vision-Language Models. **arXiv preprint arXiv:2503.15892**, 2025.

ZHANG, Duzhen et al. Mm-llms: Recent advances in multimodal large language models. **arXiv preprint arXiv:2401.13601**, 2024.

ZHANG, Shengyu et al. Instruction tuning for large language models: A survey. **arXiv preprint arXiv:2308.10792**, 2023.

ZHANG, Xiaoman et al. Pmc-vqa: Visual instruction tuning for medical visual question answering. **arXiv preprint arXiv:2305.10415**, 2023.

ZHOU, Juexiao; HE, Xiaonan et al. SkinGPT-4: an interactive dermatology diagnostic system with visual large language model. **arXiv preprint arXiv:2304.10691**, 2023.

ZHOU, Yucheng; SONG, Lingran; SHEN, Jianbing. Training medical large vision-language models with abnormal-aware feedback. **arXiv preprint arXiv:2501.01377**, 2025.